



PROJET STATAPP — ENSAE PARIS

Prédiction bayésienne des flux de migration dans le monde

Romain, Varnel, Ishagh et Louise

8 mai 2026

Résumé

Ce projet adopte une démarche méthodologique progressive pour aborder la prédiction des flux migratoires mondiaux. Partant d'un modèle de gravité linéaire et d'algorithmes d'apprentissage statistique (*Random Forest*, *XGBoost*) pour dégager des premiers phénomènes comme la trappe à pauvreté, nous répliquons ensuite le modèle bayésien hiérarchique de N.Welch et A.Raftery [1], référence de la littérature. L'horizon de prédiction de ce modèle est théoriquement très éloigné mais il souffre d'un manque d'information économétrique pour réagir à des chocs de très court terme. Nous proposons alors un modèle bayésien hiérarchique (*Hurdle ARX-ZTNB*) enrichi de covariables macroéconomiques et géopolitiques. Cette architecture gère nativement la nature discrète des flux et l'hétéroscédasticité géographique (loi *ZTNB*), la masse de 51% de zéros parmi les couloirs migratoires mondiaux (composante *Hurdle*), ainsi que l'hystérésis migratoire (composante *ARX*). Il améliore l'ensemble des métriques standards par rapport à l'état de l'art : MAE inférieure, couverture des intervalles de crédibilité à 95 % améliorée, et un gain de 30 points de MAPE sur des horizons de prédiction d'un à cinq ans.

Table des matières

1	Introduction	1
2	Données et construction de la base	2
2.1	Source des données	2
2.2	Construction et préparation du fichier	2
2.3	Valeurs manquantes	3
2.4	Analyses descriptives des flux de migration	4
3	Revue de Littérature	6
4	Approche Méthodologique	7
4.1	Le Modèle de Gravité	7
4.2	L'Apprentissage Statistique : flexibilité et capture des non-linéarités	8
4.3	Le Modèle Hiérarchique Bayésien	9
5	Modélisation et résultats	9
5.1	Modèle de gravité et PPML	9
5.2	Random Forest et XGBoost	10
5.2.1	Random Forest	10
5.2.2	XGBoost	11
5.3	Modélisation bayésienne	12
5.3.1	Modèle (baseline) répliqué de Welch & Raftery (2022)	12
5.3.2	Modèle Hurdle ARX-ZTNB sur-mesure pour prédictions de court terme	13
6	Conclusion générale et perspectives	23
A	Annexes (retours cliquables vers le corps du rapport)	25
A.1	Compléments et figures pour les parties 1 à 5.2	25
A.2	Brève digression technique sur l'algorithme HMC-NUTS	29
A.3	Dictionnaire des variables et sources de données	29
A.4	Formalisation technique : distribution ZTNB, critère PSIS-LOO et hyper-régression	31
A.5	Diagnostic de convergence de l'algorithme HMC-NUTS pour notre modèle	34
A.6	Classification par régions M49 de l'ONU et seuils ROC adaptatifs	37
A.7	Limites de l'optimisation post-hoc des seuils de décision	39

1 Introduction

La migration internationale est aujourd'hui l'une des composantes les plus dynamiques et complexes de la démographie mondiale. Dans un monde de plus en plus interconnecté, comprendre et anticiper les flux migratoires est devenu une priorité pour les décideurs publics, tant pour la gestion des infrastructures que pour l'équilibre des marchés du travail. Pourtant, contrairement aux stocks de migrants (le nombre de personnes nées à l'étranger), les flux migratoires (les déplacements annuels) sont extrêmement difficiles à mesurer. De nombreux pays ne disposent pas de registres fiables, ce qui crée des "trous" massifs dans les données mondiales.

Pour pallier ce manque d'observations, l'économie internationale s'appuie sur le modèle de gravité. Inspiré de la physique de Newton, ce modèle postule que l'intensité des échanges (ici, les migrants) entre deux pays dépend de leur "masse" respective — souvent mesurée par la population et le niveau de richesse — et est freinée par la distance qui les sépare. Bien que simple en apparence, ce modèle doit faire face à des défis statistiques majeurs, notamment l'hétéroscédasticité des données et la difficulté de prédire des flux pour des paires de pays n'ayant jamais eu d'échanges par le passé.

L'article de Welch et Raftery [1], marque une étape décisive. Leur force réside dans une proposition radicalement différente du benchmark habituel. Contrairement au modèle de gravité qui multiplie les variables explicatives, leur modèle ne repose que sur l'évolution temporelle de la série des flux de migration.

En se focalisant exclusivement sur la dynamique propre aux données historiques des flux, sans ajouter aucune autre variable exogène (ni distance, ni population, ni indicateurs socio-économiques), ils parviennent à obtenir des performances prédictives bien supérieures aux modèles de gravité classiques. C'est là le cœur de leur contribution : démontrer que la série temporelle elle-même contient une information plus riche et plus prédictive que les variables structurelles traditionnellement utilisées.

Ce projet se propose d'explorer cette frontière méthodologique à travers quatre objectifs fondamentaux :

- **Améliorer le modèle de gravité** : Nous reprenons le modèle de référence pour tenter de l'améliorer. L'idée est d'identifier des variables critiques à côté desquelles les auteurs auraient pu passer, afin de voir si une spécification plus fine peut réduire l'écart de prédiction.
- **Diagnostiquer les faiblesses du Benchmark** : Nous chercherons à comprendre précisément pourquoi le modèle de gravité "pêche" dans ses prédictions là où le modèle hiérarchique bayésien excelle.
- **Implémenter et surpasser le modèle bayésien** : Enfin, nous procéderons à l'implémentation du modèle hiérarchique bayésien. L'objectif ultime sera de tester des ajustements ou des raffinements pour voir s'il est possible de faire encore mieux que les résultats originaux des auteurs.

La structure de ce travail s'articule autour de quatre axes principaux. Dans un premier temps, nous détaillons la construction de notre base de données multidimensionnelle, en mettant en exergue les défis liés à la fusion de sources hétérogènes et la problématique des données

manquantes, qui constitue une limite inhérente à l'analyse des flux migratoires mondiaux. La deuxième section est consacrée à une analyse descriptive approfondie, visant à broser un panorama des dynamiques migratoires sur la période 1990-2015. Par la suite, nous exposons la trajectoire méthodologique adoptée : partant de l'optimisation du modèle de gravité classique, nous explorons des approches non linéaires par apprentissage statistique (Random Forest, XG-Boost) avant d'implémenter le modèle hiérarchique bayésien de référence. Enfin, nous présentons et discutons nos résultats en comparant les performances prédictives "hors échantillon" de ces différentes spécifications afin d'identifier le modèle le plus robuste pour l'anticipation des flux futurs.

2 Données et construction de la base

Cette section détaille la provenance des informations utilisées et les étapes nécessaires à la création de notre base de travail. L'objectif était de construire un fichier "bilatéral" (par paire de pays) couvrant 200 pays et territoires sur la période 1990-2015, avec un pas de temps de 5 ans.

2.1 Source des données

Pour capturer la complexité des mouvements migratoires, nous avons initialement fusionné quatre grandes sources de données internationales :

Les flux migratoires (Base Abel & Cohen, 2019) : C'est notre variable d'intérêt. Puisque les flux annuels réels sont rarement enregistrés de manière fiable, cette base utilise les variations des "stocks" de migrants de l'ONU pour estimer les entrées et sorties réelles.

La démographie (ONU - WPP 2019) : Nous avons extrait la population totale, mais aussi le ratio de dépendance (PSR : ratio population active 15–64 ans sur population dépendante) et le taux de mortalité infantile (IMR : mortalité avant 5 ans). Ces variables servent d'indicateurs de la structure de la population et du niveau de développement humain.

L'économie et le développement (Banque Mondiale - WDI) : Nous avons récupéré le PIB en dollars courants et le taux d'urbanisation. Pour tester l'influence de la situation économique sur le départ, nous avons également créé une variable de PIB retardé ($t - 1$).

La géographie et l'histoire (CEPII) : Cette source fournit les distances entre les capitales (D_{ij}) ainsi que les variables binaires essentielles au modèle de gravité : frontière commune (LB_{ij}), langue officielle commune (OL_{ij}), liens coloniaux passés (COL_{ij}), etc. Une description exhaustive de toutes ces variables figure en Annexe A.3.

Nous verrons que l'ajout de variables géopolitiques (UCDP Armed Conflicts et V-Dem Democracy Indicators) s'est aussi avéré cruciale pour notre modèle bayésien final, détaillé en 5.3.2.

2.2 Construction et préparation du fichier

Le passage de données « par pays » à une base « par paire de pays » a nécessité un travail d'ingénierie important :

- **Harmonisation ISO3** : Chaque source utilise parfois des noms de pays différents. Nous avons converti toutes les entités en codes standards (ISO 3166-1 alpha-3) pour garantir que les jointures soient parfaites.
- **La « double jointure »** : Pour chaque flux (ex : du pays d'origine i vers le pays de destination j), nous avons associé les caractéristiques de l'émetteur (PIB, population, etc.) et celles du récepteur. Chaque ligne du fichier final contient donc les informations des deux pays concernés par le mouvement.
- **Gestion des flux nuls** : De nombreuses paires de pays n'enregistrent aucun flux migratoire. Nous avons choisi de conserver ces « zéros », car l'absence de migration est une information en soi que nos modèles (notamment le PPML et le Machine Learning) doivent apprendre à expliquer.

2.3 Valeurs manquantes

La principale limite de ce travail réside dans la disponibilité des données. Le tableau ci-dessous résume l'état de complétude de notre base. La base de données finale repose sur un échantillon de **200 pays uniques**. Sur le plan théorique, pour chaque année, le nombre de couples (origine-destination) possibles est de $200 \times 199 = 39\,800$.

Le tableau 1 détaille l'évolution du remplissage de notre matrice au fil des années. On observe que si la couverture est très large dès 1990 (96,03 %), elle atteint son maximum théorique seulement en 2015.

TABLE 1 – Évolution du remplissage de la matrice bilatérale (1990-2015)

Année	Couples observés	Couples théoriques	Taux de remplissage
1990	38 220	39 800	96,03 %
1995	38 220	39 800	96,03 %
2000	38 220	39 800	96,03 %
2005	38 612	39 800	97,02 %
2010	39 402	39 800	99,00 %
2015	39 800	39 800	100,00 %

Sur l'ensemble de la période d'étude (1990-2015), le volume théorique de notre base de données devrait s'élever à 238 800 observations ($200 \times 199 \times 6$). En pratique, après la construction de la matrice brute, nous travaillons sur un échantillon effectif de **230 146 lignes**. Cet écart initial de 8 654 observations, bien que numériquement faible (environ 3,6 % du total), n'est pas distribué de manière aléatoire.

En réalité, cette attrition ne traduit pas un biais de sélection structurel défavorable aux pays en développement. L'absence de ces couples s'explique strictement par l'accès récent à la souveraineté de jeunes États (le Soudan du Sud en 2011, Curaçao en 2010, le Monténégro en 2006, et le Timor-Leste en 2002), ce qui empêche de les inclure dans les premières périodes historiques de la base.

Sur cet échantillon effectif de **230 146 observations**, la disponibilité des données varie selon la nature des indicateurs. Le tableau 2 regroupe les variables clés par bloc thématique pour

illustrer la dégradation de l'information au fur et à mesure que l'on affine les prédicteurs économiques. **Toutes les variables sont présentées plus en détails en même temps que le modèle de gravité, en 4.1.**

TABLE 2 – Taux de complétude par catégorie de variables

Bloc thématique	Variables	Non-nulles	Remplissage
Identifiants & Flux	<i>orig, dest, flow</i>	230 146	100 %
Démographie (ONU)	P_{it} , PSR_i , IMR_{it}	230 146	100 %
Urbanisation	<i>urban_it, urban_jt</i>	230 146	100 %
Géographie (CEPII)	D_{ij} , LB_{ij} , OL_{ij} , COL_{ij} , LL_i , LA_i	230 146	100 %
Économie retardée	<i>log_gdpcap_lag</i>	214 596	93,2 %

L'estimation d'un modèle économétrique complet impose que chaque observation dispose de l'intégralité des prédicteurs. En pratique, l'effet cumulé des valeurs manquantes dicte la taille finale de l'échantillon d'estimation.

Nous aboutissons à un échantillon final de **214 596 observations**, ce qui correspond à un taux de survie global de **93,2 %** par rapport à l'échantillon effectif. Nous perdons ainsi mécaniquement près de 6,8 % de nos données initiales lors de la fusion avec les variables macroéconomiques.


Cette seconde vague d'attrition s'explique par la non-standardisation des remontées de PIB pour quatre territoires d'outre-mer isolés¹. Nous parvenons ainsi à un échantillon final qui conserve une excellente représentativité des dynamiques migratoires mondiales : la perte d'observations relève de singularités géopolitiques et administratives marginales plutôt que d'un défaut systémique des appareils statistiques internationaux, écartant ainsi le risque d'un biais de sélection endogène dans nos prédictions.

2.4 Analyses descriptives des flux de migration

Cette section propose une lecture croisée des dynamiques migratoires globales afin d'identifier les faits stylisés que nos futurs modèles devront capturer. L'analyse conjointe du volume mondial et des évolutions relatives révèle d'abord un paradoxe central : si le volume global des flux affiche une croissance quasi-linéaire depuis 1995, cette apparente stabilité cache des trajectoires régionales divergentes. Comme l'illustre la [figure 1](#), l'explosion des flux sortants africains, dont l'indice dépasse 200 en 2010 (base 100 en 1990), contraste avec la maturité et la stabilité des flux européens. Cette accélération suggère que les modèles de gravité classiques devront être complétés par des variables capables de capturer ces changements de rythme, ou par des approches plus flexibles comme le modèle hiérarchique bayésien.


1. L'Île Christmas, l'Île de Guam, Mayotte et les Îles Vierges américaines.

FIGURE 1 – Evolution du volume global (gauche) ; evolution relative par continent (droite)



Par ailleurs, le passage de l'échelle intercontinentale à l'analyse fine des corridors permet de mieux comprendre la structure de la variance des données. La migration mondiale n'est pas un phénomène diffus mais extrêmement polarisé. Si l'Asie domine les échanges vers l'Europe et l'Amérique, cette dynamique est en réalité portée par des couloirs spécifiques et ultra-dominants. Le corridor Mexique-USA ou les axes reliant l'Asie du Sud aux pays du Golfe en sont les exemples les plus frappants. Ces "autoroutes migratoires" confirment que la proximité géographique, les différentiels économiques massifs et les liens historiques constituent le moteur principal des flux, validant ainsi la structure fondamentale de l'équation de gravité que nous chercherons à optimiser.

FIGURE 2 – Migration intercontinentale(gauche) ; corridors les plus actifs (droite)



En guise de synthèse finale, la [figure 13](#) (en annexe) offre une pesée spectaculaire des masses migratoires en jeu. Elle résume en une image le déséquilibre structurel mondial : l'écrasante domination démographique de l'Asie, véritable moteur du système, relègue les autres continents au rang d'acteurs secondaires en termes de volume brut. Cette image saisissante illustre le défi majeur qui attend nos modélisations : parvenir à capturer mathématiquement un phénomène dont l'essentiel de la variance est dicté par quelques géants démographiques.

3 Revue de Littérature

La modélisation des flux migratoires a longtemps été dominée par une approche héritée de la physique spatiale, principalement à travers le prisme du modèle de gravité. Inspiré des travaux de Timbergen [2] sur le commerce international, ce cadre théorique postule que la migration entre deux entités est une fonction directe de leurs masses respectives (généralement mesurées par la population ou le PIB) et une fonction inverse de la distance qui les sépare. Cette vision déterministe a été affinée au fil des décennies, notamment par Silva et Tenreyro [3] qui, en introduisant l'estimateur Poisson Pseudo-Maximum Likelihood (PPML), ont permis de corriger les biais liés à l'hétéroscédasticité et à la présence massive de flux nuls dans les matrices bilatérales. Cependant, bien que ces modèles excellent à expliquer les structures historiques des échanges, leur capacité prédictive à long terme demeure limitée par leur dépendance à des variables exogènes qui sont elles-mêmes sujettes à d'importantes erreurs de projection.

Face aux limites de l'approche structurelle, une rupture méthodologique majeure s'est opérée avec l'introduction des modèles probabilistes par l'équipe de Raftery au début des années 2010. Initialement appliqués aux taux de fécondité et de mortalité pour les Nations Unies, ces modèles bayésiens hiérarchiques ont radicalement changé la manière dont l'incertitude est quantifiée dans les prévisions démographiques. Les travaux de Raftery [4] ont jeté les bases d'une approche où les paramètres d'un pays sont considérés comme des tirages au sein d'une distribution mondiale, permettant ainsi de stabiliser les prédictions pour les nations disposant de peu de données historiques en apprenant de l'expérience collective des autres pays.

La contribution centrale de Welch et Raftery [1] constitue le point de rupture sur lequel s'appuie notre étude. Leur thèse est audacieuse : ils démontrent qu'un modèle fondé exclusivement sur la dynamique temporelle des flux passés surpasse systématiquement les modèles de gravité classiques en termes de performance prédictive. En traitant la migration comme une série temporelle auto-régressive complexe, ils soutiennent que l'inertie des réseaux migratoires et les effets de sentier contiennent une information bien plus riche que les variables géographiques ou économiques statiques. C'est ici que le modèle de gravité "pêche", car il traite chaque période comme une observation indépendante, ignorant ainsi la mémoire des flux qui constitue pourtant le moteur principal des mouvements de population contemporains.

Notre travail se rapproche de cette littérature en adoptant le modèle de Welch et Raftery comme étalon de mesure, mais il s'en distingue par une volonté de réhabilitation de l'information structurelle. Là où les auteurs rejettent les variables exogènes au profit de la seule série temporelle, nous faisons l'hypothèse que l'échec de la gravité n'est pas dû à la non-pertinence des indicateurs économiques, mais à la rigidité des formes fonctionnelles linéaires traditionnelles. En intégrant des outils de Machine Learning non-linéaires, comme le Random Forest, et en affinant la spécification du modèle de gravité, nous cherchons à vérifier si un signal structurel bien modélisé peut encore apporter une valeur ajoutée aux prédictions purement temporelles. Nous explorons ainsi une zone grise pour tenter de surpasser leur modèle bayésien actuel.

4 Approche Méthodologique

4.1 Le Modèle de Gravité

Le modèle de gravité constitue le socle historique de l'analyse des flux spatiaux. Si sa forme initiale repose sur une analogie physique, son raffinement au cours des soixante dernières années en a fait un outil d'une précision redoutable pour l'économie internationale, capable de capturer les déterminants profonds des mouvements de population. Cette idée, introduite formellement en économie par Timbergen [2] pour le commerce international, trouve ses racines migratoires bien plus tôt dans les travaux de Ravenstein [5]. Dans ses « Lois de la migration », ce dernier observait déjà que la majorité des migrants ne parcourent que de courtes distances et que les courants migratoires se dirigent préférentiellement vers les grands centres industriels.

Un individu décide de migrer si le gain de salaire attendu dans le pays de destination, modulé par l'écart de richesse entre les deux pays (facteurs de *Pull*), surpasse les coûts du mouvement (facteurs de friction). Ces coûts sont incarnés par la distance physique, mais aussi par les barrières culturelles, linguistiques et administratives. Sous sa forme multiplicative, le modèle de gravité postule que le flux m_{ijt} entre une origine i et une destination j à l'instant t dépend des caractéristiques propres à chaque pays et de leur proximité relative. Le benchmark classique consiste à linéariser cette relation en utilisant une spécification log-log estimée par les Moindres Carrés Ordinaires (OLS). Dans notre projet, nous avons enrichi la spécification pour dépasser les simples variables de masse :

$$\begin{aligned} \log m_{i,j,t} = & \beta_0 + \beta_1 \log P_{i,t} + \beta_2 \log P_{j,t} + \beta_3 \log D_{i,j} + \beta_4 \log \text{PSR}_{i,t} + \beta_5 \log \text{PSR}_{j,t} \\ & + \beta_6 \log \text{IMR}_{i,t} + \beta_7 \log \text{IMR}_{j,t} + \beta_8 \log \text{urban}_{i,t} + \beta_9 \log \text{urban}_{j,t} \\ & + \beta_{10} \log \text{LA}_i + \beta_{11} \log \text{LA}_j + \beta_{12} \text{LL}_i + \beta_{13} \text{LL}_j \\ & + \beta_{14} \text{LB}_{i,j} + \beta_{15} \text{OL}_{i,j} + \beta_{16} \text{COL}_{i,j} + \beta_{17}(t - 2000) + \beta_{18}(t - 2000)^2 + \varepsilon_{i,j,t} \end{aligned} \quad (1)$$

où $P_{i,t}$ est la population du pays d'origine, $D_{i,j}$ la distance entre capitales, PSR le ratio de soutien potentiel (population active 15–64 ans sur population dépendante), IMR le taux de mortalité infantile à cinq ans, LA la superficie du pays, LL une indicatrice d'enclavement, $\text{LB}_{i,j}$ une indicatrice de frontière commune, $\text{OL}_{i,j}$ de langue officielle commune et $\text{COL}_{i,j}$ de lien colonial historique.

L'introduction du PIB par habitant retardé ($\text{GDP}_{i,t-1}$) constitue une innovation méthodologique cruciale : elle permet de traiter le problème d'endogénéité. En effet, l'utilisation du PIB de l'année précédente assure que nous mesurons l'impact pur de la situation économique sur la décision de départ. De plus, l'ajout de variables de structure comme la mortalité infantile (IMR) et le taux d'urbanisation permet de capturer des dimensions du développement humain que le PIB seul ne saurait résumer.

Malgré sa simplicité, l'estimation par OLS présente deux failles majeures. La première est le problème des flux nuls : dans une base mondiale, de nombreux corridors n'enregistrent aucune migration. Le logarithme de zéro étant indéfini, l'OLS force soit à supprimer ces observations (créant un biais de sélection), soit à ajouter une constante arbitraire qui biaise les coefficients. La seconde limite est liée à Silva et Tenreyro [3]. Ils ont démontré dans leur article séminal *The Log of Gravity*, qu'en présence d'hétéroscédasticité, les estimateurs OLS sont biaisés. Pour corriger ces

défauts, nous mobilisons l'estimateur PPML. Devenu le standard, il permet d'estimer le modèle dans sa forme multiplicative originale, gère naturellement les flux nuls et offre une robustesse remarquable à l'hétéroscédasticité.

4.2 L'Apprentissage Statistique : flexibilité et capture des non-linéarités

La transition de l'économétrie structurelle vers l'apprentissage statistique (*Machine Learning*) marque un changement de paradigme fondamental dans notre étude. Si le modèle de gravité impose une forme fonctionnelle stricte dictée par la théorie, les algorithmes de *Machine Learning* adoptent une approche agnostique, cherchant à maximiser la précision prédictive en laissant les données révéler elles-mêmes la complexité des relations entre les variables.

L'intérêt majeur du *Machine Learning* (ML) dans la modélisation des flux migratoires réside dans sa capacité à traiter les non-linéarités et les interactions complexes que les modèles linéaires, même sophistiqués comme le PPML, peinent à capturer. En économétrie classique, nous supposons que l'effet d'une variable est constant sur tout l'échantillon. Or, la réalité migratoire suggère l'existence de seuils : l'impact d'une augmentation du PIB sur l'émigration peut être nul dans les pays extrêmement pauvres, positif dans les pays à revenu intermédiaire, puis négatif pour les pays les plus riches. Les modèles de ML, par leur structure arborescente, identifient naturellement ces points de rupture.

Dans le cadre de ce projet, nous mobilisons deux algorithmes phares de la littérature : les **Forêts aléatoires (Random Forest)** et le **Gradient Boosting (XGBoost)**. La Forêt aléatoire, popularisée par Breiman [6], repose sur le principe du *bagging* (*Bootstrap Aggregating*). En construisant une multitude d'arbres de décision indépendants sur des sous-échantillons de données et de variables, puis en moyennant leurs prédictions, l'algorithme réduit drastiquement la variance et le risque de sur-apprentissage.

En complément, nous utilisons **XGBoost (eXtreme Gradient Boosting)**, qui représente l'état de l'art actuel pour les données tabulaires. Contrairement à la forêt aléatoire, XGBoost utilise le *boosting* : les arbres sont construits de manière séquentielle, chaque nouvel arbre cherchant à corriger les erreurs de prédiction des précédents en minimisant une fonction de perte spécifique. Cette approche permet d'obtenir une précision supérieure sur les corridors migratoires les plus atypiques. Dans notre base, où des variables peuvent avoir des effets croisés très fins, XGBoost est capable d'identifier que l'influence de l'urbanisation sur le départ dépend potentiellement du niveau de mortalité infantile ou de la distance géographique, sans que nous ayons à spécifier manuellement ces termes d'interaction.

L'apport de ces modèles à notre projet est double. D'une part, ils servent de « frontière de performance » : si XGBoost prédit beaucoup mieux que notre OLS ou notre PPML, cela prouve que les théories de la gravité sont trop simplistes pour rendre compte de la réalité des données. D'autre part, via l'analyse de l'importance des variables, ces modèles nous permettent de classer de manière objective quels facteurs pèsent réellement le plus sur les flux mondiaux, offrant ainsi une perspective nouvelle qui vient compléter ou infirmer l'intuition économique traditionnelle.

4.3 Le Modèle Hiérarchique Bayésien

Le troisième volet de notre méthode repose sur les travaux de Welch et Raftery [1]. Contrairement aux modèles de gravité ou de machine learning, ce modèle bayésien choisit de ne pas utiliser de variables externes comme le PIB, la distance. Son principe est simple : pour prédire les migrations futures, le meilleur indicateur est le passé du flux lui-même. Cette approche mise sur l’inertie migratoire : une fois qu’un couloir de migration est établi, il a tendance à se maintenir tout seul, peu importe les variations économiques immédiates.

Techniquement, ce modèle utilise une structure hiérarchique qui permet de partager de l’information entre les pays. Si les données sur un trajet précis sont insuffisantes ou de mauvaise qualité, le modèle utilise les tendances observées sur l’ensemble des autres pays pour stabiliser sa prédiction. C’est ce qu’on appelle le mécanisme de pooling (mise en commun). Contrairement aux modèles classiques qui traitent chaque paire de pays séparément, ce cadre bayésien estime à la fois une tendance mondiale et des ajustements spécifiques à chaque couloir migratoire.

Cette méthode s’appuie sur les recherches de Azose et Raftery [7], qui ont montré que les modèles basés uniquement sur le temps sont souvent plus précis que les modèles de gravité complexes pour prévoir les flux internationaux. En ignorant les variables externes, ils évitent d’intégrer du « bruit » ou des erreurs de mesure liées aux statistiques économiques parfois peu fiables. Dans notre projet, ce modèle nous sert de point de comparaison final : il permet de vérifier si l’ajout de nos variables économiques améliore vraiment la prédiction, ou si le passé des flux suffit à lui seul pour anticiper l’avenir.

En résumé, nous opposons trois visions : la théorie économique (Gravité), la flexibilité des données (ML) et l’influence du passé (Bayésien). Cette comparaison nous permet de voir quelle approche est la plus efficace pour prédire les mouvements de population dans un monde complexe.

5 Modélisation et résultats

Dans cette section, nous allons présenter les résultats des différents modèles que nous avons entraînés pour répondre à notre problématique.

5.1 Modèle de gravité et PPML

L’analyse de notre base de données révèle que 51 % des flux migratoires bilatéraux sont nuls, ce qui représente un défi pour l’estimation des modèles de gravité. Pour traiter cette caractéristique, nous avons d’abord adopté une approche classique par les moindres carrés ordinaires (OLS) en utilisant la transformation $\ln(flow + 1)$, avant de mobiliser l’estimateur PPML (Pseudo Poisson Maximum Likelihood). L’intégration du PIB par tête retardé (tableau 6) dans ces spécifications s’avère déterminante : elle permet d’augmenter le pouvoir explicatif du modèle, portant le R^2 de 57% à 60 %.

Le passage au modèle PPML apporte un éclairage radicalement différent et plus rigoureux sur les volumes migratoires réels. Sa force réside dans sa capacité à traiter les flux en niveaux, accordant ainsi un poids plus juste aux grands corridors migratoires mondiaux, là où l’OLS tend à surévaluer les micro-variations des petits flux. Le contraste le plus frappant concerne le PIB et les indicateurs sociaux à l’origine : alors qu’ils étaient prédominants en OLS, ils deviennent statistiquement nuls en PPML. En réalité, le PPML montre que si le facteur d’attraction de

la destination reste puissant avec un coefficient de +0,54, la richesse du pays de départ n'explique pas la masse globale des sorties. Cette contradiction majeure entre les deux méthodes statistiques pose un jalon crucial pour la suite : le machine learning devra trancher en explorant les non-linéarités complexes pour comprendre si la richesse agit différemment selon le niveau de développement initial.

La comparaison de nos résultats avec ceux de Welch & Raftery [1] valide notre première hypothèse : l'intégration du PIB retardé améliore la précision du modèle de gravité. Notre spécification OLS obtient un MAPE de 258 %, soit une performance six fois supérieure à celle du modèle de gravité original des auteurs (1 565 %). Ce gain massif de précision relative prouve que les indicateurs de richesse ne sont pas des variables accessoires, mais des composantes fondamentales pour modéliser la propension migratoire de manière proportionnelle, notamment pour les flux de taille intermédiaire.

5.2 Random Forest et XGBoost

Dans cette partie, nous présentons les résultats de l'entraînement du Random Forest et du XGBoost, afin de comparer leurs prédictions à celle des modèles précédent et celui de Welch et Raftery.

5.2.1 Random Forest

Optimisé via des courbes de validation (figure 8), notre Random Forest adopte une structure robuste qui prévient tout sur-apprentissage en imposant un consensus minimal par feuille. L'équilibre maintenu entre le R^2 d'entraînement (0,81) et celui de test (0,74) démontre une bonne capacité de généralisation, confirmant que le modèle capture les lois structurelles plutôt que le bruit des données.

Sur le plan des performances, ce modèle surclasse nettement les benchmarks de Welch et Raftery (2019). Avec un MAE de 2.27, nous réduisons l'erreur de volume de 25 % par rapport à leur modèle de gravité (3.0) et divisons par quatre l'erreur de leur modèle Poisson Hurdle (10.0). La supériorité est encore plus flagrante sur le MAPE : notre score de 487 % surpasse les 1 565 % de leur modèle de gravité et s'avère cinquante fois plus précis que leur modèle Hurdle (25 649 %), prouvant l'importance capitale de l'intégration du PIB et du traitement des non-linéarités dans la prédiction des flux mondiaux.

L'analyse de l'importance des prédicteurs (figure 7) confirme la hiérarchie des déterminants migratoires tout en validant nos hypothèses initiales. Si la distance (23 %), les masses démographiques de l'origine et de la destination restent les piliers de la migration, le rôle du développement humain et économique est ici clairement démontré. Le PIB par tête à l'origine figure dans le haut du classement avec une importance de 6,7 %, ce qui confirme qu'il s'agit d'une composante fondamentale pour expliquer les flux mondiaux. Notons également la puissance prédictive de la mortalité infantile à la destination (15,8 %), qui surpasse le PIB seul, suggérant que les migrants sont attirés par des environnements offrant une sécurité sanitaire et sociale globale.

L'analyse des dépendances partielles (figure 9) démontre que le PIB n'agit pas comme un simple poids linéaire, mais comme un moteur complexe dont l'influence varie selon le stade de développement des nations. Pour le pays d'origine, le Random Forest révèle une nette « bosse migratoire », ou « trappe à pauvreté » : la hausse du revenu favorise l'émigration à partir d'un certain seuil identifié autour de 18 000 \$ de PIB/habitant, en levant les contraintes de liquidité des ménages, avant de freiner les départs une fois qu'un seuil de prospérité locale est atteint. À l'inverse, le pays de destination exerce un effet d'attraction constant et proportionnel à sa richesse, sans aucun signe de saturation. Cette distinction fondamentale, que seul le machine learning parvient à modéliser sans biais, explique la supériorité de notre approche sur les spécifications classiques et valide l'importance capitale des variables de richesse dans la prédiction des flux mondiaux.

En outre, le modèle fait de mauvaises prédictions (figure 10) dans les zones où des facteurs extra-économiques prédominent. Les fortes sous-estimations (en bleu, comme en Syrie ou en Afghanistan) révèlent l'incapacité du modèle à capter les chocs brutaux liés aux conflits et à l'instabilité politique. En revanche, le modèle affiche une précision remarquable (zones blanches) dans les régions de stabilité structurelle, notamment en Amérique du Sud et en Occident. Dans ces zones, la migration suit une "physique" prévisible : elle répond docilement aux signaux du PIB, de la distance et de la démographie, sans être perturbée par des crises exogènes. Les flux y sont principalement dictés par la rationalité économique et la proximité géographique, ce qui valide la solidité de notre Random Forest pour les contextes stabilisés.

5.2.2 XGBoost

L'implémentation de l'algorithme XGBoost marque l'aboutissement de notre stratégie prédictive, en fixant le MAE à 2.11, soit une amélioration notable par rapport aux 2.27 du Random Forest. Ce gain de performance s'accompagne d'une robustesse accrue : avec un R^2 de 0,82 en entraînement et 0,76 en test, validant ainsi une modélisation qui n'apprend pas par cœur le bruit des données historiques. Le MAPE chute également à 426 %, confirmant que le passage au gradient boosting permet de mieux capturer la distribution des flux, tout en surclassant définitivement les modèles de gravité classiques de la littérature.

Cette supériorité du Boosting sur le Bagging (Random Forest) s'explique par sa nature séquentielle : là où la forêt se contente de moyenniser des arbres indépendants, XGBoost construit chaque nouvel arbre pour corriger spécifiquement les résidus (erreurs) des précédents.

L'analyse de l'importance des variables sous XGBoost (figure 12) révèle un basculement structurel majeur : la frontière commune (LB_{ij}) devient le premier prédicteur (19,6 %), devançant désormais la distance physique. Ce résultat suggère que pour l'algorithme, la continuité territoriale agit comme le catalyseur primaire des flux, avant même le coût kilométrique. On note également la persistance du signal sanitaire via la mortalité infantile à destination (12,4 %) et l'émergence de l'héritage colonial (10,5 %) comme facteurs clés. Enfin, la validation du PIB par habitant décalé dans le top des variables confirme que la richesse relative des nations reste un moteur indispensable.

TABLE 3 – Comparaison des performances prédictives (Validation hors-échantillon 2015)

Méthodes	MAE (en milliers)	MAPE (en %)
<i>(Welch & Raftery, 2022)</i>		
Moyenne historique	1.2	139
Persistance	1.0	79
Modèle de gravité	3.0	1 565
Poisson Hurdle model	10	25 649
<i>(Nos modèles)</i>		
Modèle de gravité + PIB	3.95	258
PPML + PIB	3.17	11 721
Random Forest	2.27	487
XGBoost	2.11	426

5.3 Modélisation bayésienne

5.3.1 Modèle (baseline) répliqué de Welch & Raftery (2022)

Le modèle développé par Welch & Raftery [1] s'avère très robuste à long terme. S'inscrivant dans la continuité conceptuelle des travaux de Azose & Raftery [7], cette méthodologie répond à l'impossibilité d'estimer directement une matrice de flux bilatéraux massive et fortement parcimonieuse en reposant sur une **factorisation bayésienne hiérarchique**. Le problème est décomposé en deux processus conditionnellement indépendants : l'émigration totale (Outflow) et l'allocation spatiale (Inflow).

Architecture mathématique Le premier sous-modèle estime le volume total de départs en isolant l'effet démographique. Soit $P_{i,t}$ la population du pays d'origine i au temps t . Le modèle s'applique sur le logarithme du taux d'émigration $\delta_{i,t}$, régi par un processus autorégressif d'ordre 1 (AR(1)) stationnaire :

$$\log(\delta_{i,t}) \sim \mathcal{N}(\mu_i + \phi_i(\log(\delta_{i,t-1}) - \mu_i), \sigma_i^2) \quad (2)$$

où μ_i est la moyenne historique à long terme, ϕ_i le coefficient de mémoire temporelle, et σ_i^2 la variance des chocs d'émigration.

Le second sous-modèle répartit ce volume vers les pays de destination. Puisque les parts de distribution $\pi_{i,j,t}$ vivent sur un simplexe contraint ($\sum_j \pi_{i,j,t} = 1$), une transformation CLR (*Centered Log-Ratio*) est appliquée pour projeter ces proportions sur un espace euclidien non contraint :

$$\eta_{i,j,t} = \text{clr}(\pi_{i,\cdot,t})_j = \log(\pi_{i,j,t}) - \frac{1}{D-1} \sum_{k \neq i} \log(\pi_{i,k,t}) \quad (3)$$

L'évolution temporelle de ces parts est ensuite modélisée par une marche aléatoire gaussienne : $\eta_{i,j,t} \sim \mathcal{N}(\eta_{i,j,t-1}, \psi_{i,j}^2)$. Pour contourner l'impossibilité mathématique d'appliquer un logarithme aux flux nuls ($\log(0)$), les zéros sont strictement exclus du calcul de la variance : le modèle n'apprend que sur le *support empirique* des flux strictement positifs [1].

Enfin, le nombre total d'émigrants $N_{i,t} = \lfloor \delta_{i,t} P_{i,t} \rfloor$ est injecté dans une distribution multinomiale pour obtenir le vecteur des flux bilatéraux observés :

$$M_{i,\cdot,t} \sim \text{Multinomial}(N_{i,t}, \pi_{i,\cdot,t}) \quad (4)$$

Implémentation et Bayes Empirique Dans le cadre de nos travaux, le moteur MCMC originel (NIMBLE) a été substitué par **Stan**. Afin de rendre le calcul bayésien traitable sur 200 pays, l'inférence s'appuie sur un "Bayes empirique" : les hyperparamètres des lois *a priori* (notamment pour σ_i et $\psi_{i,j}$) ont été calibrés sur les quantiles statistiques des flux d'entraînement (1990-2010), agissant comme un régularisateur face au bruit des données [7].

Résultats de l'évaluation hors-échantillon (Test sur 2015-2020) Le modèle a été évalué hors-échantillon sur la période 2015-2020 (données d'Abel & Cohen). Les résultats sont synthétisés dans le [tableau 4](#).

TABLE 4 – Comparaison des performances prédictives sur la période 2015-2020.

Métrique	HBM (Notre implémentation)	BFM [1]
MAE (milliers)	2 565.2	1 200
MAPE	227.3 %	76 %
R^2	0.5494	0.97
Couverture 95% (Bilatéraux)	92 %	93 %
Couverture 95% (Total Entrées)	94 %	87 %
Couverture 95% (Total Sorties)	95 %	92 %
Couverture 95% (Solde migratoire)	96 %	94 %

L'analyse de ces métriques révèle un contraste intéressant. D'une part, les estimateurs ponctuels (MAE et MAPE) affichent une dégradation par rapport au papier originel [1], entraînant un R^2 plus faible. La justification exacte de ce décalage sur les prédictions médianes s'avère complexe à isoler à ce stade de l'étude et nécessitera des investigations ultérieures pour être pleinement expliquée.

Cependant, **la couverture probabiliste (les intervalles de prédiction à 95 %) est un succès**. Avec 92 % des flux bilatéraux réels capturés dans nos intervalles, et une couverture allant jusqu'à 96 % sur les soldes migratoires (surpassant même les 94 % de l'article de référence), l'implémentation prouve que le modèle a correctement modélisé l'incertitude.

5.3.2 Modèle Hurdle ARX-ZTNB sur-mesure pour prédictions de court terme

Le modèle précédent a l'avantage de pouvoir prédire à des horizons théoriquement très lointains, mais souffre d'une carence économétrique majeure : il se limite à la seule dynamique inertielle (AR(1)) et démographique (populations et taux de départ). L'architecture développée ici répond à ces limites : son objectif est de fournir davantage de leviers explicatifs en entraînement pour surpasser l'état de l'art en prédiction à très court terme. Nous nous servons des travaux plus tôt dans le projet : le modèle de gravité est injecté dans une composante ARX, la carte des résidus du Random Forest nous a montré la difficulté à modéliser certaines zones

géographiques (on développe alors ici un modèle hétéroscédastique par régions du monde), et les variables importantes du Random Forest sont réinjectées.

Ce choix de densification économétrique sacrifie mécaniquement l’horizon de prévision (compromis assumé), au profit d’un outil opérationnel à très court terme pour les décideurs publics. L’objectif de domination prédictive est formellement atteint. Sur 2015, le modèle abaisse l’erreur relative (MAPE) à 46,9 %, surpassant les 76,0 % du récent benchmark de Welch & Raftery (2022), et ce sans négliger les autres métriques : la précision absolue (MAE) et la couverture probabiliste des intervalles de crédibilité sont également améliorées.

L’inférence d’un flux à l’instant t est alors conditionnelle aux variables géopolitiques et macroéconomiques observées entre l’année précédente et cinq ans en arrière. À noter qu’une spécification alternative, calibrée sur un décalage quinquennal (variables géopolitiques et macroéconomiques lagguées de 5 ans), garantit des prévisions à +5 ans avec des performances qui demeurent meilleures que notre benchmark (MAE de 1180, MAPE de 51,4%, coverage de 95,9%). **Toutefois, l’analyse se concentre ici exclusivement sur la variante à +1 an.**

Notre modèle repose sur l’algorithme HMC-NUTS via Stan, auquel on délègue l’exploration de notre espace bayésien fortement non-gaussien et de très haute dimension. Une digression technique sur cet algorithme est proposée en Annexe [A.2](#).

Données et couverture du panel

Conformément au panel défini en section [2.3](#), l’inférence porte sur 192 des 200 pays. L’entraînement a lieu sur la période 1990–2010, et la prédiction hors-échantillon en 2015.

Choix architecturaux

Premièrement, 51 % des flux bilatéraux sont nuls. Imposer une distribution unimodale (Poisson, log-normale) à l’ensemble de ces données, c’est-à-dire contraindre le modèle à placer une unique cloche autour d’une valeur centrale, ne permet pas d’expliquer simultanément pourquoi tant de paires n’échangent aucun migrant et pourquoi tant d’autres en échangeant des millions. L’architecture **Hurdle**² répond à ce diagnostic en décomposant le processus en deux temps :

1. *Le filtre d’existence (Hurdle)* : l’ouverture du couloir migratoire est modélisée par une probabilité p_{ij} via une transformation logit ($\text{logit}(p_{ij}) = X_h \beta_h + \dots$). L’état binaire final (variable de Bernoulli $Z_{ij} \in \{0 = \text{fermé}, 1 = \text{ouvert}\}$) est déterminé en confrontant cette probabilité à un seuil de discrimination optimal³.
2. *Le volume* : conditionnellement à l’existence du couloir ($Z_{ij} = 1$), l’intensité du flux est générée par une distribution de comptage strictement positive (tronquée à zéro).

La vraisemblance totale se factorise :

$$\mathcal{L}(y \mid \beta_{\text{hurdle}}, \beta_{\text{volume}}) = \begin{cases} 1 - p_{ij}(\beta_{\text{hurdle}}) & \text{si } y = 0 \\ p_{ij}(\beta_{\text{hurdle}}) \times f_{>0}(y \mid \beta_{\text{volume}}) & \text{si } y > 0 \end{cases} \quad (5)$$

2. Un Hurdle est une classe de modèles statistiques où une variable aléatoire est modélisée à l’aide de deux parties : la première est la probabilité d’atteindre la valeur 0, et la seconde partie modélise la probabilité des valeurs non nulles. Source : Wikipedia, May 2026

3. Ce seuil est dérivé d’une analyse de la courbe ROC (*Receiver Operating Characteristic*). On minimise une fonction de perte asymétrique, en pondérant les faux positifs et les faux négatifs selon la région. Détails plus bas.

En passant au log, les deux blocs se séparent : le premier ne dépend que de β_{hurdle} , le second que de β_{volume} . La matrice d'information de Fisher est donc bloc-diagonale, ce qui rend les deux composantes **asymptotiquement indépendantes (orthogonales)** : l'échantillonneur peut ajuster les paramètres du Hurdle sans interférer avec ceux du volume. En pratique, un flux de 1 million de migrants (MEX→USA) ne vient pas biaiser l'estimation de la probabilité d'ouverture d'un petit couloir.

Surdispersion et hétéroscédasticité. Les chiffres parlent d'eux-mêmes : conditionnellement à un flux strictement positif, la médiane est de 42 migrants, la moyenne de 4 271, l'écart-type de 37 446, le maximum dépasse 3,3 millions. Le ratio variance/moyenne atteint **328 312**, ce qui invalide l'hypothèse d'équidispersion de Poisson par les données elles-mêmes. La log-normale traite les flux comme des réels continus alors que leur nature est discrète, et sa variance ne croît pas proportionnellement à la moyenne.

La **Binomiale Négative Tronquée à Zéro (ZTNB)** est la **distribution retenue**. Sa formalisation mathématique complète ainsi qu'une analyse de ses moments sont détaillées en Annexe A.4. La ZTNB absorbe nativement la surdispersion via ϕ (paramètre de dispersion), et gère le support $\mathbb{N}^*$ exactement. Pour les macro-flux (moyenne $\lambda \rightarrow \infty$), le bruit discret de comptage s'efface devant l'échelle de la variance ($\text{Var} \approx \lambda^2/\phi$) et la modélisation discrète devient alors empiriquement indiscernable d'une spécification continue classique. La supériorité de la ZTNB est la plus nette pour les micro-flux (1–10 migrants) : la probabilité d'observer exactement 1, 2 ou 10 migrants ne peut pas être bien calibrée par une densité continue.




FIGURE 3 – Graphe en violons de l'hétéroscédasticité géographique par sous-région M49 de l'ONU. Les distributions *a posteriori* (les violons) du paramètre de dispersion inverse $\hat{\phi}_k$ de la ZTNB sont visibles, par sous-région M49 de l'ONU. L'épaisseur du violon en un point y est directement proportionnelle à la probabilité que ϕ_k prenne la valeur y . Un ϕ élevé signifie une faible dispersion (intervalles de crédibilité étroits, flux stables et prévisibles) ; un ϕ faible signifie une forte variance (intervalles larges, couloirs instables). L'Europe du Nord ($\hat{\phi} = 4,65$) présente la distribution la plus concentrée, tandis que l'Afrique Centrale ($\hat{\phi} = 0,77$) et l'Asie de l'Ouest ($\hat{\phi} = 0,72$) ont des corridors structurellement instables. Ce gradient valide empiriquement l'architecture hiérarchique et disqualifie Poisson, qui imposerait une dispersion uniforme à tous les clusters.

Inertie migratoire et hystérésis

Une fois qu’un couloir migratoire est ouvert, c’est-à-dire qu’un flux strictement positif a été enregistré à la période précédente (`is_mig_lag` = 1, une variable X_h du filtre Hurdle), il a une probabilité naturellement plus élevée de rester ouvert à la période suivante. C’est l’inertie des réseaux migratoires : les diasporas établies, les filières d’information⁴ et les coûts irrécupérables de l’installation⁵ créent une dépendance au sentier (**théorie des réseaux migratoires de Douglas Massey**, [8]). On peut parler d’***hystérésis migratoire*** : par analogie avec le magnétisme, où un matériau aimanté maintient une aimantation résiduelle même après disparition du champ inducteur. La rupture de l’inertie migratoire nécessite généralement un choc exogène majeur, tel qu’un conflit armé. L’idée d’ajouter des variables géopolitiques pour préciser à la fois l’*existence* et l’*intensité* de la migration s’est alors avérée cruciale.

Le phénomène d’inertie est au cœur du modèle de Welch & Raftery, qui repose exclusivement sur la dynamique temporelle des flux. Nous le formalisons par une composante **ARX(1)**⁶ dans l’équation de volume :

$$\eta_{ij,t} = \mu_{ij,t} + \rho_{ij}(\log Y_{ij,t-1} - \mu_{ij,t}) \quad (6)$$

où $\eta_{ij,t} = \log \lambda_{ij,t}$ est la log-moyenne de la ZTNB. Nous utilisons $\log Y_{t-1}$ plutôt que Y_{t-1} brut pour la cohérence dimensionnelle : un couloir MEX→USA avec $Y_{t-1} = 600\,000$ migrants injecterait une valeur astronomique dans l’équation sans cette transformation.

Le paramètre $\rho_{ij} \in (-1, 1)$ est estimé hiérarchiquement. Sa valeur médiane globale est $\hat{\rho} = 0,860$ avec un IC à 95 % de $[0,856; 0,864]$. Ce chiffre raconte aussi l’histoire du projet : dans les versions antérieures, avec moins de variables économétriques pertinentes, ρ plafonnait au-delà de 0,95 : le modèle ne savait pas se passer de l’inertie. La valeur de 0,86 dans cette version finale montre que le modèle reconnaît la persistance comme signal dominant, tout en laissant de la place à d’autres variables économétriques.

Spécification mathématique complète

Attention, partout sauf mention du contraire, l’indice $t - 1$ sous-entend une référence à la **période précédente** (donc signifie strictement $t_0 - 5$ ans).

Composante A — Filtre d’existence (HURDLE) :

$$\text{logit}(\mathbb{P}(Y_{ij,t} > 0)) = \alpha_{h,i} + \gamma_{h,j} + X_{h,ij,t-1}\beta_h + \beta_{[k]}^{\text{lag}} \cdot \mathbb{I}[Y_{ij,t-1} > 0] \quad (7)$$

X_h contient : $\log D_{ij}$ et son carré, COL_{ij} , OL_{ij} ⁷, indices V-Dem (démocratie, violence) et UCDP (conflits armés) à l’origine et à la destination (lag t-1 an à t-5 ans), et l’entraînement d’un Random Forest `logit_rf` présenté plus bas.

4. Les premiers migrants envoient des informations fiables au pays (opportunités d’emploi, routes sûres), ce qui réduit l’incertitude et le risque pour les suivants.

5. Prix initial massif pour ouvrir une route migratoire (passeurs, apprentissage d’une langue, abandon du capital social d’origine). Une fois la route ouverte, les réseaux abaissent ce coût d’entrée pour les futurs migrants.

6. **ARX(1)** pour **AutoRegressive model of order 1**, with **eXogenous variables**

7. COL_{ij} : indicatrice binaire de lien colonial historique entre i et j ; OL_{ij} : indicatrice binaire de langue officielle commune. Dictionnaire complet des variables en Annexe A.3.

Composante B — Dynamique d'intensité (ARX-ZTNB) :

$$\mu_{ij,t} = \alpha_i + \gamma_j + X_{grav,ij,t-1}\beta_{grav} \quad (8)$$

$$\eta_{ij,t} = \mu_{ij,t} + \rho_{ij}(\log Y_{ij,t-1} - \mu_{ij,t}) \quad (9)$$

$$Y_{ij,t} \mid Y_{ij,t} > 0 \sim \mathcal{ZTNB}(\exp(\eta_{ij,t}), \phi_{ij}) \quad (10)$$

X_{grav} suit la spécification gravitaire (distance, frontière commune LB_{ij} , langue officielle OL_{ij} , lien colonial COL_{ij} , tendances temporelles) **épurée des variables monadiques**, absorbées par $\alpha_i + \gamma_j$. Les variables géopolitiques lagguées sont conservées car leur dimension temporelle les rend orthogonales aux effets d'émission et d'attraction invariants dans le temps.

Structure hiérarchique et régularisation

Dans une version antérieure, chaque dyade disposait de son propre intercept, soit environ 36 000 dimensions supplémentaires à l'espace bayésien. Au bilan, nous avons trois paramètres propres à chaque dyade : cet intercept, ρ_{ij} , et ϕ_{ij} . Avec seulement $T = 5$ périodes par dyade, le ratio 3/5 faisait de l'**overfitting** une vraie menace (bien que la hiérarchie du modèle diminue théoriquement le poids effectif de chaque paramètre en dessous de 1).

La réponse a été de décomposer $\mu_{ij} = \alpha_i + \gamma_j$: chaque pays possède un effet d'émission α_i et d'attraction γ_j , distincts entre Hurdle et Volume (l'un prédit l'existence du couloir, l'autre son intensité). Les avantages sont multiples : on passe de $N_{pays} \times (N_{pays} - 1)$ à $2 \times N_{pays}$ paramètres, chaque paramètre est maintenant entraîné sur $5 \times N_{pays}$ observations au lieu de 5, et ces deux intercepts ont le pouvoir d'absorber mathématiquement tous les paramètres structurels, même ceux auxquels on ne pensait pas (dynamiques culturelles, qualité des institutions,...).

À ce stade, une évaluation du modèle via le critère bayésien PSIS-LOO (détails techniques : [9] et l'annexe A.4) a révélé une proportion non négligeable de valeurs de forme de Pareto $\hat{k} > 0,7$. Ces valeurs signalent qu'une ou plusieurs observations sont hyperinfluentes. Théoriquement, le critère PSIS-LOO suppose une indépendance conditionnelle stricte des observations, une hypothèse largement violée dans notre contexte. Mais cette évaluation nous a mis sur la piste de l'*hyper-régression* : l'introduction d'une hyper-régression sur les fondamentaux macroéconomiques (population, PIB) permet précisément de régulariser ce problème en empêchant le *posterior* de dégénérer lors de l'exclusion ou de l'absence d'une donnée en *train* ou en *test*.

Les effets pays sont alors contraints par une hyper-régression :

$$\alpha_i = Z_i \theta_{em} + \tau_\alpha \cdot \alpha_{raw,i}, \quad \alpha_{raw,i} \sim \mathcal{N}(0, 1) \quad (11)$$

Prenons l'exemple de Tuvalu, qui n'enregistre aucun flux ou presque en entraînement. Sans hyper-régression, son α_i serait tiré d'un prior vague. Avec l'hyper-régression, le moteur de Stan apprend que les pays à faible population et PIB/tête ont structurellement une émission (ou attraction) plus faible : α_i de Tuvalu est poussé vers un plancher cohérent avec ses fondamentaux, réduisant le biais si un couloir s'ouvre en 2015.

Les deux fondamentaux (Z : log-population, log-PIB/tête) présentent une corrélation modérée, contrairement au PIB total ($\log P + \log \text{PIB/tête}$) qui créerait une colinéarité parfaite. Les priors $\theta \sim \mathcal{N}(0, 0,5)$ jouent le rôle d'une régularisation Ridge.

Cette structure hiérarchique ne s’applique pas seulement à l’hyper-régression, mais à l’ensemble des paramètres du modèle : ρ_{ij} est ramené dans $(-1, 1)$ via une transformation hyperbolique ($\rho_{ij} = \tanh(\rho_{\text{global}} + \tau_\rho \cdot \varepsilon_{ij})$), ϕ_{ij} est ancré sur le cluster M49, les $\beta_{[k]}^{\text{lag}}$ varient par sous-région autour d’une moyenne globale. Partout, un paramètre brut (indice *raw*) standardisé est tiré d’une $\mathcal{N}(0, 1)$ et transformé, ce qui lisse le paysage énergétique pour le sampling HMC, et permet de dégager une ADN propre à chaque pays.

Le paramètre ϕ_{ij} est ancré sur le cluster M49 via :

$$\phi_{ij} = \phi_{\text{cluster}[k]} \cdot \exp(\tau_\phi \cdot \varepsilon_{ij}), \quad \varepsilon_{ij} \sim \mathcal{N}(0, 1) \quad (12)$$

La forme multiplicative-log garantit la positivité et impose une proportionnalité géographique. La paramétrisation non-centrée évite les “entonnoirs de Neal” qui bloquent le HMC dans les zones de forte courbure [10].

Synergie Random Forest et inférence bayésienne

L’utilisation d’un Random Forest s’est déjà avérée fructueuse plus tôt dans le projet, c’est alors naturellement que l’on a une fois de plus fait appel à lui. Par construction, le Hurdle logit ne capture que des effets linéaires. Pour capturer les non-linéarités sans exploser le nombre de paramètres bayésiens, un **Random Forest** est entraîné sur les données d’entraînement, sa probabilité prédite transformée en logit, et injectée comme covariable dans le Hurdle (variable `logit_rf`).

Le RF dispose de 52 variables : celles du Hurdle, le stock UN DESA (proxy de diaspora), `is_mig_lag`, les variables démographiques et économiques monadiques, un proxy de transitivité (si $i \rightarrow k$ et $k \rightarrow j$ sont actifs, $i \rightarrow j$ est plus probable), les indicateurs V-DEM/UCDP sur deux horizons (lag t-1 et t-5), et des fenêtres glissantes de conflits.

La forte valeur ajoutée du Random Forest, présentée en 5.2.1, justifie sa remobilisation : apprentissage fin mais robuste à l’overfitting, immunité à la multicolinéarité (autorisant l’intégration d’un maximum raisonnable de variables, 52 dans notre cas), détection native des interactions complexes et des effets de seuil, et efficacité computationnelle.

Les hyperparamètres sont optimisés par une recherche sur une grille avec validation croisée à cinq blocs, écartant tout sur-apprentissage ($AUC_{\text{train}} = 0,971$, $AUC_{CV} = 0,960$, confirmant l’absence de sur-apprentissage).

L’importance des variables révèle : `is_mig_lag` (0,447), transitivité (0,144), stock UN DESA (0,096) — soit 70 % de la puissance prédictive concentrée sur l’inertie et la diaspora. La colinéarité entre certaines variables (comme `intensity_level` et `type_of_conflict`, tirées de la base UCDP Armed Conflicts, $\text{corr} = 0,94$) est traitée asymétriquement : les deux coexistent dans le RF (les arbres sélectionnent localement la plus discriminante et sont immunisés à la colinéarité), mais `type_of_conflict` est exclu du Hurdle bayésien pour stabiliser l’identification, son signal transitant via `logit_rf`.

On trouve $\hat{\beta}^{\text{RF}} = 7,80$, IC à 95 % = $[7,65 ; 7,94]$: de très loin le coefficient le plus fort et le mieux identifié de toute la composante Hurdle. L’interprétation des covariables sera présentée plus bas.

Protocole de validation, résultats et hystérésis continentale

Le modèle est entraîné sur 1990–2010, évalué en prédiction pure sur 2015. Les prédictions sont les médianes postérieures — minimiseurs de la norme L^1 , soit la MAE, métrique naturelle pour des flux migratoires (humains).

Hystérésis continentale ($\beta_{[k]}^{\text{lag}}$). Dans les architectures antérieures à l’ajout du Random Forest, l’hystérésis était intégralement portée par β^{lag} : pour l’espace Schengen et l’Amérique latine (MERCOSUR/CAN), le coefficient atteignait $\approx +6$ et $\approx +5$, traduisant qu’une route ouverte est quasiment certaine de rester ouverte. À l’inverse, ce coefficient valait $\approx +2$ pour l’Asie de l’Ouest (Moyen-Orient), cohérent avec l’instabilité locale. Depuis l’introduction du RF, rappelons que `is_mig_lag` constitue l’une des variables les plus importantes de ce Random Forest (importance 0,447). Le signal d’hystérésis est donc désormais largement capturé par `logit_rf` avant même d’entrer dans Stan, et $\beta_{[k]}^{\text{lag}}$ joue un rôle de *régularisation résiduelle* plutôt que de signal principal. Cela explique les valeurs négatives observées dans le tableau de diagnostic (Annexe A.5). Elles ne signifient pas que l’inertie est négative, mais que Stan, ayant déjà accès à l’information via `logit_rf`, corrige à la marge.

La variation continentale reste néanmoins bien identifiée : le coefficient varie de $-2,96$ (Asie de l’Est, routes très persistantes) à $-4,27$ (Caraïbes, routes plus fragiles), et `sigma_beta_lag` = 0,40 avec IC [0,30 ; 0,56] confirme que cette hétérogénéité est statistiquement significative.


Optimisation régionalisée du seuil de décision. Plutôt qu’un seuil de décision global pour la variable de Bernoulli Z_{ij} , nous optimisons par sous-région M49 avec un poids W_{FP} supplémentaire sur les Faux Positifs proportionnel au ratio couloirs fermés/couloirs ouverts de la région. Cette optimisation a lieu sur la période de test 2015, mais n’interfère aucunement avec l’inférence de Stan : des limites à cette méthode sont discutées en Annexe A.7. Ce choix est motivé par la nature même de la métrique MAPE utilisée pour comparer les modèles. Formellement, notant $\hat{y}$ la prédiction et y le flux réel, la MAPE s’écrit :

$$\text{MAPE} = \frac{100}{N} \sum_{i=1}^N \frac{|\hat{y}_i - y_i|}{y_i + 1} \quad (13)$$

Un faux négatif ($\hat{y} = 0, y > 0$) génère une erreur relative bornée à $100 \times y/(y + 1) \leq 100\%$. Un faux positif ($\hat{y} > 0, y = 0$) génère une erreur relative potentiellement très élevée ($\hat{y}/(0 + 1) = \hat{y}$), qui peut facilement dépasser plusieurs centaines de pourcents. Pour un décideur public, prédire un flux là où il n’y en a pas conduit à allouer des ressources inutilement. Pénaliser davantage les faux positifs est donc à la fois statistiquement et politiquement justifié.

Avant régionalisation (WP global = 20) : MAE = 1 168, MAPE = 47,2 %, 43 faux positifs, 6 862 faux négatifs, accuracy = 80,6 %. Après (WP global = 25, adaptatif par cluster) : MAE = 1 159 (−9), MAPE = 46,9 % (−0,3 pt), 32 faux positifs (−25,6 %), 6 319 faux négatifs (−7,9 %), accuracy = 82,1 % (+1,5 pt). Toutes les métriques s’améliorent simultanément, ce qui valide formellement l’approche. Les détails des seuils par sous-région sont disponibles en Annexe A.6.

Cartographie des Faux Négatifs (FN) par pays d'origine



Cartographie des Faux Positifs (FP) par pays d'origine



FIGURE 4 – Cartes mondiales FP et FN résiduels de la classification Hurdle sur 2015 ($N = 36\,672$ dyades). L'échelle de la figure du haut est bien plus large que celle du bas. **Haut** : faux négatifs (6 319 couloirs ouverts non détectés), agrégés par pays d'origine. L'Amérique du Sud concentre plusieurs centaines de faux négatifs (zones rouge foncé, $FN > 60$) : les accords régionaux de libre circulation (MERCOSUR/CAN) ouvrent des couloirs que les variables disponibles et le RF n'arrivent pas à identifier avec assez de certitude. L'ajout de variables "accords migratoires" permettrait de corriger directement cette zone et illustre la marge d'amélioration encore disponible. Plus généralement, les zones rouges rassemblent des couloirs qui s'ouvrent sans historique préalable, ferment soudainement, ou pour lesquels la pénalisation forte des faux positifs a mécaniquement réduit la détection. **Bas** : faux positifs (32 au total), probablement à cause de politiques migratoires restrictives non observées. La quasi-éradication des FP résulte de l'optimisation du seuil ROC par sous-région M49 avec W_{FP} adaptatif (de 2,4 pour l'Europe de l'Ouest à 45,4 pour l'Asie Centrale, voir Annexe A.6). Vu la sévérité appliquée aux Faux Positifs, discutée précédemment, les 32 FP résiduels peuvent raisonnablement être qualifiés de *cygnes noirs*.

Toute cette architecture ainsi que ces optimisations techniques aboutissent à un surpasement net de la littérature. Comme détaillé dans le tableau 5, notre modèle abaisse drastiquement l'erreur relative (MAPE à 46,9 % contre 76,0 % pour le benchmark de Welch & Raftery), tout en garantissant une précision absolue (MAE) supérieure et une couverture probabiliste (Coverage) robuste.

TABLE 5 – Performances prédictives hors-échantillon 2015

Modèle	MAE	MAPE (+1)	Coverage 95 %	Accuracy Hurdle
Welch & Raftery (2022)	$\approx 1\,200$	76,0 %	93,0 %	—
Hurdle ARX ZTNB	1 159	46,9 %	95,9 %	82,1 %

FP : 32. FN : 6 319. Seuil ROC adaptatif par cluster M49.

Note : On préfère un modèle légèrement conservateur (95,9 %) à une sous-couverture traduisant une sur-confiance (93,0 %).




FIGURE 5 – **Gauche** : Nuage de points flux prédit (médian) vs flux réel (échelle log-log). **Droite** : Évolution de l’erreur MAE avec la magnitude des flux, triés par flux dyadiques croissants. On observe une nette corrélation positive entre la MAE et l’amplitude du flux, propriété attendue de la ZTNB : l’incertitude croît proportionnellement à la moyenne, sans biais systématique. Pour les prédictions hors-échantillon (2015), à gauche, sur les 36 672 dyades du jeu de test, l’échelle log-symétrique permet de rendre lisibles simultanément les micro-flux (1–100) et les macro-flux (> 100 000). La diagonale rouge représente la prédiction parfaite. La concentration autour de la diagonale pour les flux intermédiaires et élevés (10²–10⁶) confirme la qualité prédictive. Les quelques erreurs sur les flux inférieurs à 15 000 illustrent d’une part la précision du modèle, et d’autre part la variance inhérente à ces micro-flux (cygnes noirs). La dispersion sur les micro-flux (1–10) est une limite absolue de toute approche statistique sur des micro-flux discrets, d’autant plus qu’il existe certainement des *cygnes noirs*, tels que des diplomates, dont le flux est simplement imprévisible. La ligne de points horizontale à $y = 0$ trahit des Faux Négatifs, tandis que les quelques points alignés verticalement à $x = 0$ sont les Faux Positifs résiduels. MAE globale : 1 159 migrants.

Interprétation des coefficients




FIGURE 6 – Coefficients postérieurs et IC à 95 % pour le Hurdle (**gauche**) et le Volume (**droite**). Bleu/Rouge : significatif (IC excluant zéro) ; gris : non significatif. La magnitude de **logit_rf** ($\hat{\beta} = 7,80$) domine tous les prédicteurs du Hurdle.

Deux variables du Hurdle ont des IC larges chevauchant zéro (notamment COL_{ij}). En bayésien, un IC qui chevauche zéro signifie que les données sont compatibles avec un effet nul, pas que l'effet est nul : les priors gaussiens jouent leur rôle de régularisation et il serait incorrect de les retirer mécaniquement. Dans les versions futures, on pourra tester de laisser uniquement `logit_rf` dans le Hurdle (lui confier l'intégralité du signal de classification) pour voir si la simplification améliore la précision. Pour l'instant, $\log D_{ij}$, COL_{ij} et les variables géopolitiques semblent capter des phénomènes très résiduels que le RF ne capture pas parfaitement.

Composante Hurdle. La distance agit de façon concave : $\log D_{ij}$ (+1,54) et son carré (-1,34) indiquent que l'effet repoussoir s'atténue au-delà d'un certain seuil — les flux transcontinentaux suivent des logiques propres (diasporas, corridors historiques). La langue officielle commune ($\hat{\beta}^{OL} = +0,68$, IC [0,61 ; 0,74]) facilite significativement l'ouverture. Le lien colonial (+0,67) n'est pas significatif (IC [-0,01 ; 1,37]) : son signal est vraisemblablement absorbé par `logit_rf` via le stock UN DESA, qui capte directement les héritages migratoires coloniaux.

Côté destination, la démocratie ($\hat{\beta}^{poly-d} = -0,38$, IC [-0,45 ; -0,31]) réduit significativement la probabilité d'ouverture : les pays démocratiques ont tendance à mettre en place des politiques migratoires sélectives et des procédures d'admission plus strictes, fermant des couloirs informels. En revanche, un indice d'intégrité physique élevé à destination ($\hat{\beta}^{clphy-d} = +0,13$, IC [0,06 ; 0,19]) augmente la probabilité d'ouverture : le migrant économique régulier optimise à la fois la rente économique et la sécurité physique, davantage qu'il n'optimise l'accès aux droits politiques. L'exemple de Singapour est parlant — politique migratoire autoritaire, syndicalisation interdite sous peine de déportation, mais monopole de la violence légitime garanti et quasi-absence de criminalité. L'intensité du conflit à destination ($\hat{\beta}^{int-d} = +0,06$, IC [0,03 ; 0,09]) est positif et significatif : cela traduit des flux de rapatriement ou d'aide humanitaire vers des zones de conflit. **Côté origine**, la démocratie ($\hat{\beta}^{poly-o} = -0,29$) et l'intensité du conflit ($\hat{\beta}^{int-o} = -0,04$) réduisent la probabilité d'ouverture — signal cohérent : les conflits intenses saturent ou ferment les routes migratoires régulières existantes plutôt qu'ils n'en créent de nouvelles. La violence physique à l'origine ($\hat{\beta}^{clphy-o} = -0,02$) n'est pas significative dans le Hurdle : son signal est redondant avec l'intensité du conflit et capturé par le RF.

Composante Volume. Les coefficients gravitaires reproduisent les signes et ordres de grandeur attendus (cf. section 4.1) : distance (-1,46), frontière commune (+1,19), langue (+1,57), lien colonial (+1,52). Les variables monadiques (population, PIB) sont exclues de X_v car absorbées par $\alpha_i + \gamma_j$ — les inclure créerait une colinéarité parfaite. La quadratique temporelle ($t_{2000} = +0,22$, $t_{2000}^2 = -0,19$) capture une accélération post-2000 suivie d'une décélération, cohérente avec le durcissement des politiques migratoires.

L'effet géopolitique dissèque proprement le phénomène push/pull que les variables gravitaires classiques ne peuvent identifier. **Côté origine**, l'intensité du conflit ($\hat{\beta}^{int-o} = -0,54$, IC [-0,60 ; -0,48]) est le coefficient négatif le plus fort de toute la spécification : une guerre de haute intensité (>1000 morts/an) supprime les flux migratoires réguliers plutôt qu'elle ne les génère. Le mécanisme est contre-intuitif mais réel : la guerre ferme les aéroports, les ambassades, gèle les avoirs et paralyse les départs. Les exodes de réfugiés et mouvements humanitaires qui suivent les conflits sont capturés côté destination. La démocratie (-0,18) et la violence physique (-0,17) à l'origine réduisent également le volume, reflétant encore des contraintes au départ.

Côté destination, le signes s'inverse pour l'intensité du conflit (+0,39) : un conflit actif

à destination génère paradoxalement du flux entrant (humanitaires, militaires, ou retours forcés institutionnels). Un indice élevé d'intégrité physique (pays très sûr) augmente massivement le volume d'arrivées, comme il pouvait diminuer le volume de départs côté origine (Facteur de rétention évident). La démocratie à destination ($-0,54$) a le coefficient négatif le plus fort côté destination : les pays démocratiques sélectionnent davantage leurs immigrants et reçoivent proportionnellement moins de flux que leur attractivité économique ne le laisserait supposer. Enfin, `type_of_conflict_d_lag1` ($-0,23$, IC $[-0,31; -0,16]$) est le seul indicateur de type de conflit retenu dans le Volume (il a été exclu de l'origine pour colinéarité avec l'intensité) : plus le conflit à destination est internationalisé (guerre civile avec intervention étrangère, type 4), moins le volume entrant est important : les migrants hésitent à entrer dans une zone d'affrontement entre puissances.

Robustesse et limites

L'inférence (4 chaînes, 2 300 itérations dont 1 000 de warmup, `adapt_delta`= 0,95) présente une convergence quasi-irréprochable (voir Annexe A.5) : aucune divergence, $\hat{R} < 1,01$ et ESS > 400 sur l'ensemble des paramètres [11]. La stabilité entre les runs indépendants garantit l'absence de sur-apprentissage ($\hat{\rho} = 0,8602$ vs $0,8604$, $\hat{\beta}_{\log_D} = -1,461$ vs $-1,461$). La saturation marginale du `treedepth` (25 % des transitions pour `max_treedepth`= 12) ralentit l'exploration algorithmique sans altérer la validité de l'inférence.

Les limites structurelles du modèle s'articulent autour de deux arbitrages :

- **Horizon prédictif restreint (+1 an)** : La densification économétrique, par l'inclusion de variables géopolitiques observées à $t - 1$ an, restreint l'inférence à un an. Étendre cet horizon prédictif exigerait de prédire des conflits géopolitiques, ce qui est difficilement envisageable. Une variante du modèle avec uniquement des variables laggées de 5 ans permet des prévisions à +5 ans, toujours meilleures que le benchmark (MAE de 1 180, MAPE de 51,4 %, Coverage de 95,9 %), mais ce rapport s'est focalisé sur le modèle à horizon de +1 an.
- **Biais de classification asymétrique** : Une partie des 6 319 faux négatifs sont peut être non prédictibles : des couloirs qui s'ouvrent sans historique observable, des chocs géopolitiques absents des données disponibles, de véritables *cygnes noirs migratoires*. Mais une autre partie — difficile à quantifier précisément — est le résultat direct du choix délibéré de pénaliser sévèrement les faux positifs pour minimiser la MAPE. Prenons l'Indonésie : archipel géographiquement isolé, la distance pénalise fortement les couloirs entrants, et le seuil ROC élevé imposé par le W_{FP} achève mécaniquement la détection de couloirs qui existent pourtant en réalité. C'est un arbitrage assumé, on ne peut pas tout avoir, mais il laisse une marge d'amélioration réelle sur le Hurdle. À l'inverse, les 32 faux positifs résiduels (ayant survécu à des W_{FP} atteignant 45,4) signalent des dyades vraisemblablement bloquées par des politiques migratoires restrictives non intégrées dans le modèle.

6 Conclusion générale et perspectives

Ce rapport illustre une progression méthodologique face à la complexité des flux migratoires mondiaux. Si le modèle de gravité (linéaire) s'est avéré inadapté à la prédiction pure, sa struc-

ture fondamentale n'a pas été rejetée : elle constitue le squelette de notre architecture finale (composante *ARX*). De même, l'étape d'apprentissage (*Random Forest*, *XGBoost*) a été décisive. Elle nous a non seulement confirmé la hiérarchie des déterminants (PIB, mortalité infantile, population), mais a surtout quantifié les effets de seuil inhérents au développement économique (la fameuse "bosse migratoire" ou trappe à pauvreté). Enfin, l'analyse cartographique des résidus de ces algorithmes a mis en lumière des zones d'instabilités structurelles, nous guidant vers l'implémentation cruciale de l'hétéroscédasticité géographique dans notre modèle bayésien final. Concernant le modèle probabiliste de Welch & Raftery, qui a servi de socle à notre démarche (processus d'allocation multinomiale), notre réplication offre une couverture probabiliste exemplaire (96 %), mais un écart résiduel subsiste sur les prédictions ponctuelles, dont l'origine mathématique exacte (sensibilité des priors, hyper-paramétrisation empirique) reste à isoler.

Concernant notre modèle bayésien final, plusieurs axes d'amélioration identifiés méritent d'être poursuivis. Sur le plan des données, l'intégration des stocks de réfugiés UNHCR constitue la piste la plus prometteuse pour réduire les faux négatifs. L'ajout d'un indice de politique migratoire (DEMIG POLICY) aiderait aussi à expliquer certains faux positifs et faux négatifs concentrés dans des régions à politiques restrictives non observées. Concernant le panel total (section 2.3), une récupération manuelle des données de PIB pour les quatre territoires exclus (CLI, GUM, MYT, VIR) permettrait d'ajouter 1 548 dyades supplémentaires, soit un gain non négligeable. Les quatre autres états exclus (SSD, TLS, MNE, CUW) sont en revanche irrécupérables pour ce modèle en raison d'un historique macroéconomique trop court. Sur le plan méthodologique, les différentes architectures testées tout au long du projet ont été comparées par bon sens et par confrontation directe des métriques MAE, MAPE et Coverage. Une analyse plus formelle via des critères d'information bayésiens devra être engagée dans la suite des travaux, pour quantifier rigoureusement les gains apportés par chaque couche de complexité — hyper-régression, ajout du RF, choix de la distribution, choix de l'ordre du modèle AR(1) — et identifier les directions de simplification ou d'enrichissement les plus prometteuses. Notre modèle final bat l'état de l'art de la littérature (MAPE à 46,9 % contre 76,0 %) et prouve que l'information structurelle a sa place aux côtés de l'inertie pure. L'objectif à terme est la rédaction d'un article scientifique le moins attaquable possible, en s'appuyant sur des comparaisons formelles d'architectures, une validation sur plusieurs horizons temporels, et l'enrichissement des données.

A Annexes (retours cliquables vers le corps du rapport)

A.1 Compléments et figures pour les parties 1 à 5.2

Synthèse des résultats OLS et PPLM

TABLE 6 – Synthèse des résultats


[↑ Retour au corps du rapport \(section 4.1\)](#)

Catégorie	Variable	(1) OLS	(2) OLS	(3) PPML	(4) PPML
Démographie	$\ln(P_{it})$	0.337*** (0.004)	0.405*** (0.004)	0.655*** (0.020)	0.663*** (0.022)
	$\ln(P_{jt})$	0.293*** (0.004)	0.378*** (0.004)	0.552*** (0.020)	0.547*** (0.020)
	$\ln(D_{ij})$	-1.143*** (0.007)	-1.195*** (0.007)	-0.840*** (0.031)	-0.853*** (0.031)
	LB_{ij}	2.898*** (0.049)	2.892*** (0.050)	0.971*** (0.101)	1.039*** (0.103)
Histoire	OL_{ij}	1.449*** (0.014)	1.211*** (0.014)	0.793*** (0.058)	0.615*** (0.069)
	COL_{ij}	2.897*** (0.047)	2.716*** (0.048)	1.316*** (0.070)	1.364*** (0.068)
	$\ln(gdpcap_o_l)$	–	0.446*** (0.007)	–	-0.014 (0.043)
	$\ln(gdpcap_d_l)$	–	0.587*** (0.007)	–	0.542*** (0.053)
Socio-écon.	$\ln(IMR_{it})$	-0.608*** (0.007)	-0.143*** (0.010)	-0.036 (0.044)	-0.034 (0.062)
	$\ln(urban_{it})$	0.013 (0.011)	-0.376*** (0.013)	0.171* (0.094)	0.224** (0.098)
	Effets Fixes	OUI	OUI	OUI	OUI
	Observations	198,744	187,630	187,630	187,630
Statistiques	R^2 / Pseudo R^2	0.567	0.598	1.000	1.000

Notes : Écart-types robustes (HC1) entre parenthèses. *** p<0.01, ** p<0.05, * p<0.1.


Feature importances : Random Forest

FIGURE 7 – Contribution des variables au Random Forest [↑ Retour au corps du rapport \(section 5.2.1\)](#)




Learning curve du Random Forest

FIGURE 8 – Learning curve Random Forest [↑ Retour au corps du rapport \(section 5.2.1\)](#)



Trappe à pauvreté détectée par le Random Forest

FIGURE 9 – Effet non linéaire du PIB [↑ Retour au corps du rapport \(section 5.2.1\)](#)



Cartes des résidus Random Forest et XGBoost

FIGURE 10 – Carte des résidus de prédiction du Random Forest [↑ Retour au corps du rapport \(section 5.2.1\)](#)






FIGURE 11 – Carte des résidus de prédiction du XGBoost [↑ Retour au corps du rapport \(section 5.2.2\)](#)



Feature importances : XGBoost

FIGURE 12 – Contribution des variables au XGBoost [↑ Retour au corps du rapport \(section 5.2.2\)](#)



Synthèse des masses migratoires mondiales




FIGURE 13 – Synthèse des masses migratoires régionales [↑ Retour au corps du rapport \(section 2.4\)](#)

A.2 Brève digression technique sur l’algorithme HMC-NUTS

[↑ Retour au corps du rapport \(section 5.3.2\)](#)

Le modèle repose sur une inférence bayésienne : plutôt que de chercher un unique jeu de paramètres optimal, on cherche à caractériser l’intégralité de leur distribution de probabilité *a posteriori*, sachant les données. L’espace de ces paramètres est de très haute dimension (plusieurs dizaines de milliers de composantes), et le paysage probabiliste qui en résulte est largement non-gaussien. Pour l’explorer efficacement, l’échantillonnage est délégué à Stan [12] : une fois les priors et les équations du modèle spécifiés, le moteur C++ de Stan orchestre automatiquement l’algorithme *Hamiltonian Monte Carlo with No U-Turn Sampler* (HMC-NUTS). L’essence de l’algorithme s’inspire directement de la physique : à chaque itération, une impulsion est donnée à un point dans l’espace des paramètres bayésiens. Le gradient de la log-vraisemblance⁸ définit la topologie de l’espace, les équations de Hamilton fournissent les lois physiques pour s’y déplacer. L’exploration d’une trajectoire dans cet espace s’interrompt dès que la particule amorce un demi-tour, l’idée étant d’explorer efficacement sans redondance. Cette nouvelle position est alors soumise à un critère d’acceptation de Metropolis-Hastings, $\mathbb{P}(\text{acceptation}) = \min(1, \exp(-\Delta\mathcal{H}))$, qui pénalise les déviations majeures à la conservation de l’énergie totale. Dans un espace d’une telle dimension, cette navigation guidée par le gradient et la mécanique hamiltonienne est très largement supérieure à une marche aléatoire aveugle (Metropolis classique).

A.3 Dictionnaire des variables et sources de données

[↑ Retour au corps du rapport \(spécification Hurdle, section 5.3.2\)](#)

Cette annexe recense l’intégralité des variables exogènes mobilisées dans l’architecture Hurdle ARX ZTNB. Les indices i , j et t désignent respectivement l’origine, la destination et la période

8. Plus précisément, le gradient de la log-distribution *a posteriori* (vraisemblance * prior) mais les priors sont définis à l’avance et ne changent pas au cours d’une simulation.

quinquennale. Le suffixe `_lag1` ou `_lag5` indique un décalage temporel de un ou cinq ans par rapport au flux observé. Certaines variables sont exclusives à l'entraînement du Random Forest (pour des raisons de colinéarité et de parcimonie).

1. Géographie et Histoire (Source : CEPII)

- `log_D_ij` et `log_D_ij_sq` : Logarithme de la distance entre les capitales des pays i et j , et son carré (capture de l'effet concave).
- `LB_ij` : Variable binaire de contiguïté (frontière terrestre commune).
- `COL_ij` : Variable binaire de lien colonial historique.
- `OL_ij` : Variable binaire de langue officielle commune.
- `LL_i`, `LL_j` : Variables binaires d'enclavement (*Landlocked*). Exclusives à l'entraînement du Random Forest.
- `LA_i`, `LA_j` : Logarithme de la superficie du pays. Exclusives au RF.

2. Démographie et Macroéconomie (Sources : ONU WPP, Banque Mondiale WDI)

- `log_P_it`, `log_P_jt` : Logarithme de la population totale.
- `log_gdpcap_o_lag`, `log_gdpcap_d_lag` : Logarithme du PIB par habitant décalé ($t - 5$ ans).
- `log_gdpcap_diff` : Différentiel bilatéral de PIB par habitant, laggé de 5 ans.
- `PSR_i`, `PSR_j` : *Potential Support Ratio* (ratio population active 15–64 ans / population dépendante).
- `IMR_it`, `IMR_jt` : Taux de mortalité infantile avant 5 ans (*Infant Mortality Rate*), proxy de l'infrastructure sanitaire.
- `urban_it`, `urban_jt` : Taux d'urbanisation.

3. Institutions et Droits Humains (Source : V-Dem)

- `v2x_polyarchy` : Indice de démocratie électorale (0 à 1). Une valeur proche de 1 indique des élections libres et équitables.
- `v2x_clphy` : Indice de respect de l'intégrité physique (0 à 1). Une valeur de 1 signifie une sécurité totale (absence de meurtres politiques et de torture de la part de l'État); une valeur de 0 indique une violence étatique extrême.

4. Conflits Armés (Source : UCDP Armed Conflict Dataset)

- `intensity_level` : Intensité du conflit (0 = paix, 1 = conflit mineur [25-999 morts], 2 = guerre [>1000 morts]).
- `type_of_conflict` : Typologie de l'affrontement (e.g., interne, internationalisé).
- **Variables temporelles dérivées (exclusives au RF)** : `any_conflict_window`, `new_conflict`, `persistent_conflict`, `max_conflict`. Ces transformations capturent la cinématique du conflit sur des fenêtres glissantes (déclenchement, chronicité, pic de violence).

5. Dynamique et Réseaux Migratoires (Source : ONU DESA, Abel & Cohen)

- `is_mig_lag` : Variable binaire d'existence d'un flux strictement positif à la période précédente ($Y_{ij,t-1} > 0$). Cœur de l'inertie du modèle Hurdle.
- `log_stock_lag` : Logarithme du stock bilatéral de migrants à $t - 1$, source ONU DESA. Proxy quantitatif de la diaspora établie (exclusive au RF).
- `transitivity_proxy` : Indicateur binaire de transitivité du réseau (vaut 1 si les couloirs $i \rightarrow k$ et $k \rightarrow j$ sont actifs, augmentant empiriquement la probabilité de $i \rightarrow j$).
- `logit_rf` : Prédiction probabiliste issue de l'algorithme Random Forest (entraîné sur l'espace étendu de 52 variables), transformée par la fonction logit pour inclusion linéaire dans l'équation de la composante A Hurdle.
- `t_2000`, `t_2000_sq` : Tendances temporelles linéaire et quadratique, centrées sur l'année 2000.

A.4 Formalisation technique : distribution ZTNB, critère PSIS-LOO et hyper-régression

Formalisation mathématique de la distribution ZTNB

[↑ Retour au corps du rapport \(choix architecturaux, section 5.3.2\)](#)

La modélisation de l'intensité des flux migratoires nécessite une distribution discrète, strictement positive, et capable de gérer une forte surdispersion. Nous retenons la distribution Binomiale Négative Tronquée à Zéro (ZTNB), dérivée d'un mélange Poisson-Gamma.

Construction hiérarchique (Mélange Poisson-Gamma)

Idéalement, un flux d'individus Y suit une loi de Poisson d'intensité λ : $Y \mid \lambda \sim \text{Poisson}(\lambda)$. Cependant, le taux réel λ n'est pas statique ; il fluctue autour d'une espérance μ définie par le modèle $(X\beta)$. On introduit une composante aléatoire multiplicative ν telle que $\lambda = \mu\nu$.

Pour garantir $\lambda > 0$, la variable ν suit une loi Gamma d'espérance 1 et de variance $1/\phi$. Par conséquent, λ devient une variable aléatoire continue :

$$\lambda \sim \text{Gamma} \left(\text{forme} = \phi, \text{taux} = \frac{\phi}{\mu} \right) \quad (14)$$

La distribution marginale de Y s'obtient en intégrant la vraisemblance de Poisson sur toute la distribution de λ :

$$P(Y = y \mid \mu, \phi) = \int_0^\infty \text{Poisson}(y \mid \lambda) \times \text{Gamma}(\lambda \mid \mu, \phi) d\lambda \quad (15)$$

Le résultat analytique de cette intégrale est la Binomiale Négative standard (NB2) :

$$P(Y = y \mid \mu, \phi) = \frac{\Gamma(y + \phi)}{\Gamma(\phi)y!} \left(\frac{\phi}{\mu + \phi} \right)^\phi \left(\frac{\mu}{\mu + \phi} \right)^y \quad (16)$$

Troncature en zéro et Moments

Puisque la composante Hurdle a déjà filtré les flux nuls, l'intensité modélise un support $\mathbb{N}^*$. La probabilité d'observer un zéro sous la NB2 est :

$$p_0 = P(Y = 0 \mid \mu, \phi) = \left(\frac{\phi}{\mu + \phi} \right)^\phi = \left(1 + \frac{\mu}{\phi} \right)^{-\phi} \quad (17)$$

La densité de la ZTNB s'obtient en conditionnant l'espace des probabilités à $Y > 0$, soit en divisant la NB2 par $(1 - p_0)$:

$$f_{\text{ZTNB}}(y \mid \mu, \phi) = \frac{\Gamma(y + \phi)}{\Gamma(\phi)y!(1 - p_0)} \left(\frac{\phi}{\mu + \phi} \right)^\phi \left(\frac{\mu}{\mu + \phi} \right)^y \quad (18)$$

L'espérance conditionnelle subit une translation vers le haut :

$$\mathbb{E}[Y \mid Y > 0] = \frac{\mu}{1 - p_0} \quad (19)$$

La variance conditionnelle s'écrit :

$$\text{Var}(Y \mid Y > 0) = \frac{\mu + \frac{\mu^2}{\phi}}{1 - p_0} - \frac{\mu^2 p_0}{(1 - p_0)^2} \quad (20)$$

Interprétation de ϕ et hétéroscédasticité structurelle

Dans sa forme non tronquée, la variance de la NB2 est $\text{Var}(Y) = \mu + \frac{\mu^2}{\phi}$. Cette structure d'erreur quadratique est indispensable pour modéliser les flux mondiaux où la variance empirique écrase la moyenne ($\text{Var}(Y) \gg \mathbb{E}(Y)$), disqualifiant *de facto* la distribution de Poisson qui imposerait $\text{Var}(Y) = \mathbb{E}(Y)$.

Si $\phi \rightarrow \infty$, la variance converge vers l'espérance et la distribution se réduit asymptotiquement à une loi de Poisson (équidispersion). L'analyse isolée de la variance empirique est trompeuse. Soient deux régions :

- Une région de macro-flux (ex. : Amérique du Nord) produit mécaniquement une variance colossale dominée par le terme d'échelle μ^2 .
- Une région de micro-flux (ex. : Océanie) produit une variance minimale en valeur absolue.

Conclure que l'Océanie est plus "stable" que l'Amérique du Nord en comparant les variances brutes serait une erreur. L'extraction du paramètre ϕ dans la modélisation hiérarchique permet d'isoler l'instabilité *structurelle*, indépendamment de l'échelle (μ) du flux. Un ϕ élevé signale un corridor stable et prévisible. L'estimation de ce paramètre de dispersion inverse par cluster M49 offre ainsi une cartographie rigoureuse de l'hétéroscédasticité mondiale de la migration.

Diagnostic PSIS-LOO et rôle régularisateur de l'hyper-régression

[↑ Retour au corps du rapport \(structure hiérarchique, section 5.3.2\)](#)

Nous verrons que l'utilisation du critère PSIS-LOO n'est pas valide dans notre contexte : il a néanmoins pu nous éclairer sur l'utilisation des hyper-régression, qui ont pu rendre notre modèle plus sain et plus performant. C'est pourquoi nous présentons l'idée de ce critère ici en annexe.

La validation croisée *Leave-One-Out* (LOO-CV) classique exige de soustraire itérativement chaque observation y_i des données, puis de recompiler l'algorithme HMC sur les $N-1$ observations restantes pour générer une distribution *a posteriori* $\mathbb{P}(\theta \mid Y_{-i})$. Avec plus de 35 000 dyades, cette approche est computationnellement intraitable.

Le *Pareto Smoothed Importance Sampling* (PSIS-LOO) permet d'approximer ces distributions *a posteriori* "amputées" à partir de l'unique distribution *a posteriori* globale $\mathbb{P}(\theta \mid Y)$ issue de l'entraînement sur l'échantillon complet.

1. Mécanique analytique de l'échantillonnage d'importance

Soit Y le vecteur des N observations et Y_{-i} le vecteur privé de la i -ème observation. L'échantillonnage d'importance postule que l'on peut approcher le modèle Y_{-i} en repondérant les tirages $\theta^{(s)}$ du modèle complet Y . Le poids d'importance d'un tirage $\theta^{(s)}$ est défini par le ratio des densités *a posteriori* :

$$r_i^{(s)} = \frac{\mathbb{P}(\theta^{(s)} \mid Y_{-i})}{\mathbb{P}(\theta^{(s)} \mid Y)} \quad (21)$$

Théoriquement, le PSIS-LOO repose sur une hypothèse stricte d'indépendance conditionnelle des observations : $\mathbb{P}(Y \mid \theta) = \mathbb{P}(y_i \mid \theta)\mathbb{P}(Y_{-i} \mid \theta)$. En appliquant le théorème de Bayes au numérateur et au dénominateur, on obtient :

$$r_i^{(s)} = \frac{\frac{\mathbb{P}(Y_{-i} \mid \theta^{(s)})\mathbb{P}(\theta^{(s)})}{\mathbb{P}(Y_{-i})}}{\frac{\mathbb{P}(y_i \mid \theta^{(s)})\mathbb{P}(Y_{-i} \mid \theta^{(s)})\mathbb{P}(\theta^{(s)})}{\mathbb{P}(Y)}} = \frac{1}{\mathbb{P}(y_i \mid \theta^{(s)})} \times \frac{\mathbb{P}(Y)}{\mathbb{P}(Y_{-i})} \quad (22)$$

Les termes marginalisés $\mathbb{P}(Y)$ et $\mathbb{P}(Y_{-i})$ étant des constantes d'intégration indépendantes de θ , la dépendance du poids vis-à-vis des paramètres se réduit à :

$$r_i^{(s)} \propto \frac{1}{\mathbb{P}(y_i \mid \theta^{(s)})} \quad (23)$$

Le poids d'importance d'un tirage est donc inversement proportionnel à la vraisemblance locale de l'observation y_i . Si $r_i^{(s)} \gg 1$, le run HMC $\theta^{(s)}$ attribue une probabilité quasi-nulle à l'observation y_i . C'est l'accumulation de ces ratios extrêmes qui génère l'instabilité de l'estimateur.

2. Lissage de Pareto et diagnostic du sur-apprentissage ($\hat{k}$)

Pour stabiliser l'estimateur, l'algorithme PSIS isole les 20 % des poids les plus lourds (la queue de distribution) et y ajuste une distribution de Pareto généralisée (GPD), dont la densité s'écrit :

$$f(x \mid k, \sigma, \mu) = \frac{1}{\sigma} \left(1 + k \frac{x - \mu}{\sigma} \right)^{-\left(\frac{1}{k} + 1\right)} \quad (24)$$

Le paramètre de forme estimé, $\hat{k}$, agit comme un diagnostic direct de la topologie locale :

- Si $\hat{k} \leq 0,5$: La variance des poids est finie. Le lissage fonctionne, l'estimateur converge rapidement.
- Si $\hat{k} > 0,7$: L'espérance des poids n'est plus garantie et leur variance est infinie. Le lissage échoue. Cela indique que la distribution *a posteriori* subit une déformation brutale lorsque y_i est retiré. Autrement dit, l'observation i dicte massivement ses propres paramètres : le

modèle sur-apprend (*overfitting*) cette observation.

3. Rôle curatif de l'hyper-régression face aux observations hyper-influentes

L'observation de nombreux $\hat{k} > 0,7$ dans les versions préliminaires du modèle s'explique par deux facteurs. Le premier est structurel : l'hypothèse d'indépendance conditionnelle $\mathbb{P}(Y \mid \theta) = \mathbb{P}(y_i \mid \theta)\mathbb{P}(Y_{-i} \mid \theta)$ est intrinsèquement violée par notre composante autorégressive (ARX), ce qui gonfle mécaniquement les poids.

Le second facteur justifie l'architecture finale. Considérons un pays comme Tuvalu, ne présentant qu'un unique flux sortant y_{TUV} dans la base d'entraînement. Avec une hiérarchie classique naïve ($\alpha_i \sim \mathcal{N}(\mu_{em}, \tau)$), l'inférence de l'effet d'émission α_{TUV} repose intégralement sur ce seul flux. Si la LOO-CV retire cette observation, Tuvalu se retrouve sans aucune donnée. Son paramètre α_{TUV} s'effondre alors dans un "vide probabiliste", violemment ramené vers le *prior* global μ_{em} . Ce saut topologique majeur se traduit par un $\hat{k} \gg 0,7$.

L'introduction de l'hyper-régression vectorielle :

$$\alpha_i \sim \mathcal{N}(Z_i \theta_{em}, \tau) \tag{25}$$

modifie radicalement cette dynamique. Si l'unique flux de Tuvalu est retiré, le paramètre α_{TUV} ne chute plus vers une moyenne mondiale ignorante. Il est mécaniquement ancré par ses fondamentaux macroéconomiques (population, PIB) via le terme $Z_{TUV} \theta_{em}$. L'économie réelle agit comme un filet de sécurité structurel qui empêche la distribution de se déformer brutalement, régularisant ainsi le paysage bayésien et ramenant la variance des estimateurs IS sous le seuil critique.

A.5 Diagnostic de convergence de l'algorithme HMC-NUTS pour notre modèle

[↑ Retour au corps du rapport \(hystérésis continentale, section 5.3.2\)](#) [↑ Retour au corps du rapport \(robustesse, section 5.3.2\)](#)

TABLE 7 – Diagnostic de convergence bayésien (Partie 1) : Paramètres structurels et coefficients.

Paramètre	Médiane	IC 5%	IC 95%	ESS	$\hat{R}$	0 $\notin$ IC ?
Paramètres globaux et échelles de variance						
rho_global_monitor	0.8604	0.8562	0.8644	1321	1.0014	✓
tau_rho	0.4398	0.4211	0.4598	563	1.0099	✓
tau_em	1.6410	1.5190	1.7720	994	0.9995	✓
tau_at	1.3130	1.2040	1.4220	1058	1.0000	✓
tau_h_em	0.6568	0.5975	0.7201	984	0.9999	✓
tau_h_at	0.5018	0.4565	0.5575	1092	1.0016	✓
intercept_em	2.2160	1.0328	3.3420	2177	0.9996	✓
intercept_at	2.2330	1.0779	3.3992	2145	0.9995	✓
intercept_h_em	1.7290	0.3244	3.1603	2092	1.0000	✓
intercept_h_at	1.1985	-0.2091	2.6041	2097	1.0000	–
phi_disp_global	2.0450	1.8500	2.2350	2189	1.0000	✓
tau_phi_disp	1.4140	1.3870	1.4410	1315	1.0009	✓
mu_beta_lag	-3.6530	-3.8560	-3.4650	1131	1.0014	✓
sigma_beta_lag	0.3962	0.2959	0.5587	1385	1.0029	✓
Composante Volume (ZTNB) - β_{grav}						
log_D_ij	-1.4610	-1.5140	-1.4090	1467	1.0003	✓
LB_ij	1.1955	0.9742	1.4290	1337	1.0034	✓
OL_ij	1.5720	1.4470	1.7010	1423	1.0035	✓
COL_ij	1.5310	1.2950	1.7530	1556	1.0024	✓
t_2000	0.2200	0.1727	0.2677	1110	0.9994	✓
t_2000_sq	-0.1856	-0.2266	-0.1464	1333	1.0002	✓
v2x_polyarchy_o_lag1	-0.1883	-0.3519	-0.0147	1059	1.0069	✓
v2x_clphy_o_lag1	-0.1630	-0.2899	-0.0451	1369	1.0054	✓
intensity_level_o_lag1	-0.5380	-0.6015	-0.4766	1415	1.0044	✓
v2x_polyarchy_d_lag1	-0.5440	-0.6838	-0.3905	1129	1.0018	✓
v2x_clphy_d_lag1	0.5848	0.4685	0.6970	1317	1.0014	✓
intensity_level_d_lag1	0.3874	0.3214	0.4634	1496	1.0003	✓
type_of_conflict_d_lag1	-0.2287	-0.3053	-0.1571	1462	0.9996	✓
Composante Hurdle (Logit) - β_h						
log_D_ij	1.6465	1.3100	2.0030	2272	1.0002	✓
log_D_ij_sq	-1.4230	-1.7680	-1.1020	2268	1.0000	✓
COL_ij	0.6355	-0.0332	1.3332	2141	0.9999	–
OL_ij	0.6662	0.5986	0.7340	2223	0.9997	✓
v2x_polyarchy_o_lag1	-0.2892	-0.3670	-0.2152	1454	1.0031	✓
v2x_clphy_o_lag1	-0.0696	-0.1390	-0.0041	1533	1.0009	✓
intensity_level_o_lag1	-0.0391	-0.0708	-0.0080	2040	0.9998	✓
v2x_polyarchy_d_lag1	-0.4076	-0.4810	-0.3350	1332	0.9998	✓
v2x_clphy_d_lag1	0.1461	0.0796	0.2125	1532	1.0002	✓
intensity_level_d_lag1	0.0613	0.0278	0.0936	1861	1.0002	✓
logit_rf	7.7990	7.6530	7.9410	1835	1.0011	✓

TABLE 8 – Diagnostic de convergence bayésien (Partie 2) : Hystérésis et hyper-régressions.

Paramètre	Médiane	IC 5%	IC 95%	ESS	$\hat{R}$	$0 \notin \text{IC} ?$
Hystérésis continentale - $\beta_{\text{lag}}^{\text{m49}}$						
cluster_1	-3.8250	-4.0731	-3.5740	2320	1.0016	✓
cluster_2	-4.2740	-4.4880	-4.0580	2235	1.0001	✓
cluster_3	-3.8600	-4.2270	-3.4980	2263	1.0017	✓
cluster_4	-2.9595	-3.1860	-2.7250	2115	1.0021	✓
cluster_5	-3.6250	-3.8330	-3.3970	2111	0.9996	✓
cluster_6	-3.6520	-3.8030	-3.5010	2208	1.0004	✓
cluster_7	-3.6630	-3.8150	-3.5080	2265	0.9997	✓
cluster_8	-3.4280	-3.6220	-3.2320	2232	1.0005	✓
cluster_9	-4.1500	-4.3680	-3.9230	2301	1.0010	✓
cluster_10	-3.9920	-4.3891	-3.6120	2118	1.0006	✓
cluster_11	-3.1300	-3.3320	-2.9250	2348	1.0000	✓
cluster_12	-3.7270	-3.9010	-3.5610	2046	1.0006	✓
cluster_13	-3.5385	-3.7150	-3.3590	2098	1.0003	✓
cluster_14	-3.6110	-3.8481	-3.3680	2158	0.9994	✓
cluster_15	-3.4525	-3.6560	-3.2559	2008	1.0013	✓
cluster_16	-4.0300	-4.2060	-3.8480	2138	1.0004	✓
cluster_17	-4.1470	-4.3220	-3.9760	2122	1.0006	✓
cluster_18	-3.1480	-3.3900	-2.8860	2201	1.0001	✓
cluster_19	-3.4240	-3.5840	-3.2680	2217	0.9997	✓
Hyper-régressions monadiques - $\theta_{\text{em}}, \theta_{\text{at}}, \theta_{\text{h_em}}, \theta_{\text{h_at}}$						
theta_em[Z_1]	1.6690	1.4530	1.8540	547	1.0062	✓
theta_em[Z_2]	0.5038	0.2895	0.7136	527	1.0018	✓
theta_at[Z_1]	1.6220	1.4500	1.7830	780	1.0007	✓
theta_at[Z_2]	0.8833	0.7018	1.0490	641	1.0009	✓
theta_h_em[Z_1]	-0.1678	-0.2536	-0.0842	810	1.0023	✓
theta_h_em[Z_2]	-0.0781	-0.1713	0.0134	724	1.0040	–
theta_h_at[Z_1]	-0.2557	-0.3324	-0.1806	945	1.0018	✓
theta_h_at[Z_2]	-0.3568	-0.4355	-0.2811	990	1.0021	✓

Notes : Seuils de convergence HMC respectés ($\hat{R} < 1,01$ et $ESS > 400$).

Interprétation des coefficients d’hystérésis continentale difficile car ils régularisent l’effet de `is_mig_lag` contenu dans l’entraînement du Random Forest.

TABLE 9 – Diagnostic de convergence bayésien (Partie 3) : Dispersion géographique ZTNB.

Paramètre	Médiane	IC 5%	IC 95%	ESS	$\hat{R}$	$0 \notin \text{IC} ?$
Dispersion géographique ZTNB - ϕ_{cluster}						
cluster_1	4.6430	4.3060	4.9892	1779	1.0005	✓
cluster_2	2.1030	1.9310	2.3030	1715	1.0006	✓
cluster_3	4.0540	3.7589	4.3720	1675	1.0007	✓
cluster_4	3.9885	3.6750	4.3291	1737	0.9998	✓
cluster_5	1.6285	1.4350	1.8320	1659	0.9996	✓
cluster_6	1.0100	0.9249	1.1040	1706	0.9996	✓
cluster_7	0.7236	0.6572	0.7894	1761	0.9996	✓
cluster_8	0.8697	0.7605	0.9859	1655	1.0050	✓
cluster_9	1.1220	0.9635	1.2930	1699	1.0000	✓
cluster_10	3.9730	3.5699	4.4250	1792	1.0004	✓
cluster_11	2.6520	2.3410	2.9670	1874	0.9994	✓
cluster_12	1.8780	1.7010	2.0870	1732	1.0007	✓
cluster_13	2.0915	1.9120	2.2830	1688	0.9999	✓
cluster_14	1.5870	1.3990	1.7770	1700	1.0023	✓
cluster_15	1.2710	1.1440	1.4130	1662	1.0031	✓
cluster_16	0.7660	0.6924	0.8507	1665	1.0001	✓
cluster_17	1.9640	1.7600	2.1960	1842	1.0012	✓
cluster_18	1.5740	1.3610	1.8270	1708	0.9996	✓
cluster_19	1.1200	1.0440	1.2080	1626	1.0036	✓
Diagnostics HMC						
Divergences totales : 0 Treedepth saturé (≥ 10) : 25 % $\hat{R}_{\text{max}}$: 1,010						

Notes : Seuils de convergence HMC respectés ($\hat{R} < 1,01$ et $ESS > 400$).

Le treedepth saturé à 25 % indique que le sampler atteint sa limite d’exploration environ une fois sur quatre, ralentissant le mélange sans compromettre la convergence ($\hat{R} < 1,01$ partout). Ce point sera traité dans une version ultérieure par augmentation de `max_treedepth`.

A.6 Classification par régions M49 de l’ONU et seuils ROC adaptatifs

Classification par régions M49 de l’ONU

Afin de modéliser l’hétérogénéité spatiale de la dispersion (ϕ_{cluster}) et de l’hystérésis continentale ($\beta_{[k]}^{\text{lag}}$), les 192 pays de l’échantillon sont regroupés selon la classification géographique M49 édictée par la Division de statistique des Nations Unies (UNSD). Le tableau 10 détaille la correspondance entre l’indexation du modèle bayésien (Stan cluster) et les codes régionaux M49.

TABLE 10 – Correspondance entre l’indexation du modèle (Stan) et les régions M49

Cluster Stan (k)	Code M49	Région
1	11	Europe du Nord
2	12	Europe du Sud
3	13	Europe de l’Ouest
4	14	Europe de l’Est
5	15	Afrique du Nord
6	16	Afrique de l’Ouest
7	17	Afrique de l’Est
8	18	Afrique Centrale
9	19	Afrique Australe
10	21	Amérique du Nord
11	22	Amérique Centrale
12	23	Caraïbes
13	24	Amérique du Sud
14	30	Asie de l’Est
15	34	Asie du Sud
16	35	Asie du Sud-Est
17	53	Océanie
18	143	Asie Centrale
19	145	Asie de l’Ouest

Seuils ROC adaptatifs par sous-région M49

[↑ Retour au corps du rapport \(optimisation du seuil, section 5.3.2\)](#)

Le tableau ci-dessous détaille les seuils de décision et poids W_{FP} utilisés par sous-région ONU M49. Le poids est proportionnel au ratio couloirs fermés/ouverts de la région, normalisé par le ratio global, puis borné dans l’intervalle $[2,0 ; 50,0]$ pour éviter les extrêmes. Un ratio faible (peu de couloirs fermés) induit un W_{FP} bas et un seuil permissif ; un ratio élevé induit un W_{FP} élevé et un seuil très restrictif.

TABLE 11 – Seuils ROC adaptatifs par sous-région M49 ($W_{FP,global} = 25$)

Sous-région	Seuil	W_{FP}	Ratio ferm./ouv.	n_{pos} / n_{neg}
Europe du Nord	0,958	6,4	0,24	1489 / 361
Europe du Sud	0,972	17,1	0,64	1238 / 797
Europe de l'Ouest	0,744	2,4	0,09	1186 / 109
Europe de l'Est	0,978	13,3	0,50	1232 / 618
Afrique du Nord	0,973	26,3	0,99	650 / 646
Afrique de l'Ouest	0,994	38,5	1,45	1207 / 1753
Afrique de l'Est	0,985	41,5	1,57	1298 / 2033
Afrique Centrale	0,996	43,7	1,65	629 / 1036
Afrique Australe	0,989	27,5	1,04	454 / 471
Amérique du Nord	0,929	3,6	0,13	489 / 66
Amérique Centrale	0,985	35,3	1,33	555 / 740
Caraïbes	0,984	42,6	1,61	1065 / 1712
Amérique du Sud	0,976	25,6	0,96	1225 / 1181
Asie de l'Est	0,943	23,4	0,88	689 / 607
Asie du Sud	0,993	23,1	0,87	889 / 776
Asie du Sud-Est	0,996	29,8	1,12	871 / 979
Océanie	0,986	44,0	1,66	834 / 1386
Asie Centrale	0,810	45,4	1,71	341 / 584
Asie de l'Ouest	0,973	19,0	0,72	1941 / 1389
Seuil ROC global de référence (non régionalisé) : 0,986.				

A.7 Limites de l'optimisation post-hoc des seuils de décision

[↑ Retour au corps du rapport \(optimisation du seuil, section 5.3.2\)](#)

La calibration des seuils régionaux optimaux par maximisation d'une fonction de gain asymétrique pondérée par W_{FP} a été réalisée en confrontant les probabilités issues du modèle bayésien aux réalisations effectives (y_{true}) de l'année de test 2015.

D'un point de vue strict, cette procédure induit une fuite d'information (*data leakage*) : la règle de décision a été calibrée sur le même échantillon que celui utilisé pour l'évaluation finale hors-échantillon. Nuancons :

- **Intégrité de l'inférence bayésienne** : Le seuil ROC constitue une règle de décision *post-hoc*. Il n'interfère à aucun moment avec le moteur d'inférence. L'intégralité des distributions *a posteriori* est figée à l'issue de l'échantillonnage Stan, qui est entraîné exclusivement sur les données 1990-2010. Le pouvoir prédictif du modèle n'est donc pas altéré.
- L'asymptotique de l'échantillon de test ($N > 36\,000$ dyades) garantit une grande stabilité locale des seuils identifiés.
- **Résolution par validation temporelle stricte** : Pour purger définitivement ce biais de calibration lors de travaux futurs, un protocole de validation croisée temporelle stricte devra être implémenté :
 1. *Entraînement du modèle (Stan)* : 1990-2005.
 2. *Calibration des seuils ROC (W_{FP} et maximisation)* : 2010.

3. *Évaluation pure hors-échantillon (Seuils figés) : 2015.*

Références

- [1] Nathan G WELCH et Adrian E RAFTERY. « Probabilistic forecasts of international bilateral migration flows ». In : *Proceedings of the National Academy of Sciences* 119.35 (2022), e2203822119.
- [2] Jan TINBERGEN. « Shaping the world economy ; suggestions for an international economic policy ». In : (1962).
- [3] JMC Santos SILVA et Silvana TENREYRO. « The log of gravity ». In : *The Review of Economics and statistics* (2006), p. 641-658.
- [4] Adrian E RAFTERY et al. « Bayesian probabilistic population projections for all countries ». In : *Proceedings of the National Academy of Sciences* 109.35 (2012), p. 13915-13921.
- [5] Ernest George RAVENSTEIN. « The laws of migration ». In : Royal Statistical Society. 1885.
- [6] Leo BREIMAN. « Random forests ». In : *Machine learning* 45.1 (2001), p. 5-32.
- [7] Jonathan J AZOSE et Adrian E RAFTERY. « Estimation of emigration, return migration, and transit migration between all pairs of countries ». In : *Proceedings of the National Academy of Sciences* 116.1 (2019), p. 116-122.
- [8] Douglas S MASSEY et al. « Theories of international migration : A review and appraisal ». In : *Population and development review* 19.3 (1993), p. 431-466.
- [9] Aki VEHTARI et al. « Pareto smoothed importance sampling ». In : *Journal of Machine Learning Research* 25.72 (2024), p. 1-58. URL : <http://jmlr.org/papers/v25/19-556.html>.
- [10] M. J. BETANCOURT et Mark GIROLAMI. *Hamiltonian Monte Carlo for Hierarchical Models*. 2013. DOI : [10.48550/arXiv.1312.0906](https://doi.org/10.48550/arXiv.1312.0906). arXiv : [1312.0906 \[stat.ME\]](https://arxiv.org/abs/1312.0906). URL : <https://arxiv.org/abs/1312.0906>.
- [11] Aki VEHTARI et al. « Rank-normalization, folding, and localization : An improved R-hat for assessing convergence of MCMC (with discussion) ». In : *Bayesian analysis* 16.2 (2021), p. 667-718. DOI : [10.1214/20-BA1221](https://doi.org/10.1214/20-BA1221).
- [12] Bob CARPENTER et al. « Stan : A probabilistic programming language ». In : *Journal of statistical software* 76.1 (2017), p. 1-32. DOI : [10.18637/jss.v076.i01](https://doi.org/10.18637/jss.v076.i01).